



Pontificia Universidad Javeriana

Facultad de Ingeniería

Procesamiento de lenguaje natural

Luis Gabriel Moreno Sandoval, PhD

Taller: Recuperación de Información Aplicada a Entrevistas y Libros de la Comisión de la Verdad

Objetivo del Laboratorio

Desarrollar un proceso de Recuperación de Información (IR) para determinar qué entrevistas contenidas en el documento JSON están relacionadas con testimonios o secciones de los libros de la Comisión de la Verdad (CEV). Se espera que los estudiantes apliquen técnicas de procesamiento de lenguaje natural para analizar y relacionar las narraciones de entrevistas con textos específicos de los libros, utilizando métricas específicas para medir la relevancia de los resultados.

Recursos:

- Libros de la Comisión de la Verdad (CEV):

<https://drive.google.com/drive/folders/1W9UOdkqnAcztnFZ8xresW4ZeZ2pqXe4v?usp=sharing>

- Entrevistas:

https://drive.google.com/file/d/1XeFS_mQFmTLQ_VUiODTBO5eONWv-Ege5/view?usp=sharing

- Tesauro CEV:

<https://drive.google.com/file/d/1XgZzMtFQp0RzwqdY7Em5q5ProsWLMMX4/view?usp=sharing>



Actividades:

1. Extracción y preparación del corpus

- Extraer las secciones, testimonios o partes relevantes de cada uno de los libros de la CEV. Definir la morfología de documento para recuperar (Explicar como la van a hacer).
 - Preprocesar los textos extraídos y las entrevistas para su análisis, incluyendo pasos como tokenización, eliminación de stop words, y lematización.
 - Entregar el corpus limpio y estructurado en un formato adecuado para su análisis comparativo
-

2. Análisis Exploratorio del Corpus:

- Realizar un análisis exploratorio de los corpus generados. Esto puede incluir:
 - Estadísticas descriptivas de longitud de texto, diversidad léxica, y frecuencia de términos.
 - Generación de nubes de palabras para visualizar los términos más frecuentes en cada corpus.
 - Comparación de patrones léxicos entre los textos de los libros y las entrevistas.
-

3. Desarrollo del Modelo de Recuperación de Información:

- Implementar un modelo de IR que relacione las narraciones de las entrevistas con los textos generados de los libros.
 - Utilizar técnicas como la vectorización de textos (TF-IDF) para representar los textos y facilitar la búsqueda y comparación.
 - Entregar un informe detallado con los resultados obtenidos y las observaciones realizadas durante la implementación del modelo.
-

4. Implementación de Métricas de Relevancia:

- Implementar manualmente las métricas de Rocchio y Okapi BM25 para medir la relevancia de las coincidencias encontradas entre entrevistas y textos de los libros.
 - Crear funciones personalizadas que calculen estas métricas y expliquen su funcionamiento.
 - Comparar los resultados de relevancia obtenidos con ambas métricas y discutir las diferencias.
-



5. Comparación de corpus:

- Realizar una comparación de los textos de las entrevistas que tengan temas similares con los textos de los libros preprocesados.
 - Generar un gráfico de “heatmap” que puedas dar cuenta del relacionamiento sugerido.
-

6. Presentación de resultados:

Elaborar un informe final que integre todos los resultados obtenidos, incluyendo:

- Descripción del proceso seguido para la extracción y preparación del corpus.
 - Análisis exploratorio del corpus.
 - Descripción y análisis del modelo de IR desarrollado.
 - Evaluación de la relevancia utilizando las métricas implementadas.
 - Incluir conclusiones y posibles mejoras para futuras iteraciones del proyecto.
-

Entregables:

- Corpus Extraído y Preprocesado: Dos archivos con los textos extraídos en formato raw (crudo) y los corpus preprocesados de los libros.
- Análisis Exploratorio: Informe con los resultados del análisis exploratorio del corpus.
- Modelo de IR: Código y reporte detallado del modelo de Recuperación de Información.
- Funciones de Métricas: Código de las funciones para calcular las métricas de Rocchio y Okapi BM25.
- Comparación de las entrevistas con los libros: entregar un cuadro y un gráfico que pueda describir que entrevistas están vinculadas a los textos de cada libro de acuerdo con el segmentado que generaron.
- Informe Final: Documento que integre todos los componentes anteriores y presente una evaluación crítica del proceso y los resultados.