

¿Los medios narran el mismo país? Cobertura y encuadres en titulares de prensa colombiana (2018–2026)

Entrega 2 · EDA avanzado, representación de textos y propuesta metodológica

Abel Albuez Sánchez · Kelly Joane León Torres · Juan Camilo Torres Peña · Jesús David Romero Melo

Grupo 1 · Procesamiento de Lenguaje Natural · Maestría en Ingeniería de Sistemas y Computación / Maestría en Inteligencia Artificial · Pontificia Universidad Javeriana

I. CORRECCIONES RESPECTO A LA ENTREGA 1

La Entrega 1 planteó la pregunta y un prototipo probado con un evento y tres medios ficticios, sin cifras del corpus histórico. La Tabla 1 resume los cambios.

Tabla 1. Correcciones y modificaciones respecto a la Entrega 1.

Aspecto	Entrega 1	Entrega 2	Razón
Corpus	Un evento, tres medios ficticios	Dos cortes reales: Duque (708 768 registros) y Petro (984 590 titulares)	Describir medios reales
Ventana	2006–2026, cinco gobiernos	Dos gobiernos completos, cada uno como un corte	Un gobierno por corte controla la agenda; dos permiten compararlos
Medios	Diez catalogados	Cinco en ambos cortes; Cambio solo en Petro	El Espectador, Semana y W Radio no cubren las ventanas
Unidad	Texto completo, por oración	Titular reconstruido desde la URL	El cuerpo no está disponible de forma comparable
Limpieza	Normalizar espacios	Minúsculas, sin tildes ni puntuación; <i>stopwords</i> ; separación de contenido de servicio	El titular ya llega sin tildes
Medidas	Previstas, sin cifras	Zipf, TTR, MATTR, MTLT, MSTTR, K de Yule, n-gramas, coocurrencias, χ^2 con tamaño de efecto, LDA	Pendiente de la Entrega 1
Recursos léxicos	—	Tesoro temático, ontología de actores, vocabulario de temas	Describir temas y actores
Evento	evento_id manual	Recuperación del mismo hecho por similitud	Inviabile a mano a esta escala

1.1. Antecedentes

Tres trabajos orientan el análisis. Entman [1] define el encuadre como la selección de algunos aspectos de la realidad y su mayor relevancia en el texto: un mismo evento admite varios encuadres. Hamborg [2] muestra que la elección de palabras y el etiquetado de un mismo actor activan connotaciones distintas, y propone estudiarlos con PLN. Wang et al. [3] separan dos dimensiones que el término «sesgo» suele mezclar: *qué* se cubre (selección) y *cómo* se cubre (encuadre). Esta entrega sigue esa separación: las palabras clave y los tópicos describen la cobertura; la diversidad léxica y los n-gramas describen el lenguaje. El encuadre requiere validación humana, que se propone en la Sección V.

1.2. Construcción del corpus

El servicio news-retrieval recorre mes a mes los sitemaps que cada medio publica. Ningún medio incluye el titular en sus sitemaps históricos, por lo que se reconstruye desde la URL: `.../congreso-aprueba-reforma-pensional-123` se convierte en

«Congreso aprueba reforma pensional». Se pierden tildes, comillas y puntuación.

Tabla 2. Conteos por corte y medio. Las unidades difieren: registros en Duque, titulares en Petro.

Medio	Duque (2018–2022)	Petro (2022–2026)
El Tiempo	263 145	406 313
Blu Radio	166 593	203 738
Caracol	109 384	94 108
La República	91 801	105 876
RCN	77 747	130 180
Cambio	98	44 375
Total	708 768 (707 553 con título)	984 590

Las dos cifras suman 1 693 358, pero esa suma no equivale a titulares disponibles. En el corte Duque, Cambio tiene solo 98 registros de seis días (archivo desde agosto de 2022) y se excluye. RCN empieza el 1 de septiembre de 2018. La fecha tiene precisión de día en 670 147 registros y solo de mes en 38 621.

II. ANÁLISIS EXPLORATORIO AVANZADO

2.1. Preprocesamiento

Todos los titulares se normalizan a minúsculas, sin tildes ni puntuación, porque los reconstruidos desde la URL ya llegan así. Se eliminan *stopwords* y tokens muy cortos; los nombres de actores y lugares se conservan. En el corte Petro se separa además el contenido de servicio (lotería, horóscopo, opinión, multimedia). Los dos cortes se procesaron con pipelines distintos, así que cada comparación entre medios se hace dentro de un mismo corte.

2.2. Descripción del corpus

Tabla 3. Corte Petro por medio. *Servicio*: lotería, horóscopo, opinión y multimedia. *Con tema*: noticias con al menos un tema del tesoro.

Medio	Titulares	Por mes	Palabras	% servicio	Noticias	% con tema
El Tiempo	406 313	8 465	14,1	6,6	379 578	32,2
Blu Radio	203 738	4 245	15,0	14,9	173 300	32,3
RCN	130 180	2 712	12,2	2,7	126 613	28,8
La República	105 876	2 206	11,8	1,5	104 267	26,9
Caracol	94 108	1 961	15,9	6,1	88 386	27,8
Cambio	44 375	924	11,3	0,2	44 308	40,1
Total	984 590	20 512		6,9	916 452	




Figura 1. Volumen mensual de titulares por medio (corte Petro).

Lo observado:

- **El volumen es estable** en los dos cortes. En el corte Duque crece hasta 2021 en casi todos los medios (Figura 2).
- **El Tiempo domina el corpus:** aporta el 41 % de los titulares en el corte Petro y el 37 % en el corte Duque.
- **Caracol y Blu Radio escriben los titulares más largos** (15–16 palabras); Cambio, La República y RCN, los más breves (11–12).
- **El contenido de servicio se concentra en pocos medios:** es el 14,9 % de Blu Radio (lotería 10,0 %) y el 6,6 % de El Tiempo (opinión 4,8 %), y es prácticamente nulo en Cambio. Sin separarlo, las frecuencias describen los productos del portal y no su manera de informar.
- **Hay 32 368 titulares repetidos** en el corte Duque (programas, emisiones, lotería), lo que hace optimistas las pruebas estadísticas.




Figura 2. Artículos por año y medio (corte Duque; 2018 y 2022 parciales).

2.3. Recursos léxicos: tesaurus y ontología

Se aplicaron tres recursos, todos como métodos de diccionario: un titular recibe una categoría si contiene alguno de sus términos. Esto los hace transparentes, pero exige validarlos sobre el corpus [4].

- **Tesaurus temático** *config/topics.yaml* (corte Petro): 7 temas generales, 35 subtemas y 209 términos de entrada.
- **Ontología de actores** *config/actores.yaml* (corte Petro): 11 clases (gobierno nacional, oposición, Congreso, rama judicial, órganos de control, fuerza pública, grupos armados, movimientos sociales, gremios, gobiernos locales, internacional), 51 actores y 204 alias. Se excluyeron alias ambiguos como «fiscal» («regla fiscal») y el análisis se hace por clase, que es robusto a ambigüedades como «uribe» (Álvaro o Miguel).
- **Vocabulario de tres temas elegidos** (corte Duque): Reforma tributaria, Conflicto armado y Corrupción.




Figura 3. Porcentaje de noticias por tema general del tesaurus (corte Petro).

Lo observado (corte Petro):

- **Cobertura del tesaurus:** entre el 27 y el 40 % de las noticias toca algún tema. Política es el más frecuente en todos los medios (Figura 3).
- **La República tiene perfil económico:** es el único medio donde Economía supera el 3 % (8,6 %), y casi no cubre seguridad (0,7 %, frente a 4,8–9,3 % en los demás).
- **Cambio es el más político:** tiene la mayor proporción de Política (14,6 %) y Justicia (5,5 %), y menciona al gobierno nacional en el 10,3 % de sus noticias, frente a 3,8–6,9 % en los demás.
- **Actor más mencionado:** Gustavo Petro en Blu Radio, Cambio y Caracol; Estados Unidos en El Tiempo, La República y RCN.

Para aplicar la ontología al corte Duque hay que anclarla en el tiempo: entre 2018 y 2022 Petro pertenece a la clase *oposición*.

2.4. Ley de Zipf (corte Duque)

Sobre 4 737 325 tokens y 98 418 palabras distintas, la relación entre rango y frecuencia es casi lineal en escala log-log ($r = -0,982$; pendiente $-1,035$; $R^2 = 0,969$). Los cinco medios principales se comportan igual (pendientes de $-1,03$ a $-1,11$). Es una correlación descriptiva [5]: indica que el corpus se comporta como lenguaje natural, pero no prueba una ley de potencia [6] ni dice nada sobre sesgo. Cambio, con 476 tokens, no es comparable.

2.5. Diversidad léxica

La razón tipo/token (TTR) depende del tamaño del texto, así que cada medio se midió con el mismo número de tokens. En el corte Petro se usaron MATTR [7] y MTLTD [8] sobre muestras de 200 000 tokens; en el corte Duque, TTR por rarefacción (100 submuestras de 10 000 tokens), MSTTR y K de Yule [9].

Tabla 4. Diversidad léxica, corte Petro (media de cinco muestras; K de Yule: menor es más diverso).

Medio	MATTR	MTLTD	K de Yule
Cambio	0,629	163,1	119,0
El Tiempo	0,625	158,1	119,8
RCN	0,624	168,3	117,9
La República	0,617	147,3	138,3
Blu Radio	0,585	130,3	117,6
Caracol	0,576	115,7	129,4

Tabla 5. Diversidad léxica, corte Duque (TTR con rarefacción y su intervalo de 2,5–97,5 %).

Medio	TTR (rarefacción)	MSTTR ₅₀	K de Yule
Caracol	0,480 [0,473–0,489]	0,958	8,80
El Tiempo	0,476 [0,470–0,484]	0,954	7,35
Blu Radio	0,469 [0,462–0,476]	0,960	7,57
RCN	0,453 [0,444–0,461]	0,957	8,17
La República	0,447 [0,440–0,455]	0,972	7,77




Figura 4. TTR con rarefacción a 10 000 tokens por medio (corte Duque).

Lo observado:

- **Corte Petro:** Blu Radio y Caracol son los menos diversos (MATTR 0,576–0,585), lo que coincide con plantillas de titular repetidas («pico y placa en...», «quedó en video»).
- **Corte Duque:** con igual número de tokens, La República tiene el TTR más bajo (0,447) y Caracol el más alto (0,480). La diferencia es de 0,033, alrededor de un 7 %; la afirmación previa de que La República era «35 % más diversa» no se sostiene.
- **El orden depende de la medida:** La República tiene el MSTTR más alto (0,972).

Que dos medidas o dos cortes ordenen distinto a los medios muestra que la diversidad depende del procedimiento. No mide calidad de escritura ni sesgo.

2.6. N-gramas

Tabla 6. Bigramas más frecuentes por medio (corte Petro; contenido de servicio excluido).

Blu Radio	Cambio	Caracol	El Tiempo	La República	RCN
mañanas blu	gustavo petro	estados unidos	estados unidos	estados unidos	noticias rcn
presidente petro	estados unidos	presidente petro	gustavo petro	petróleo hoy	emisión noticias
estados unidos	álvaro uribe	gustavo petro	donald trump	donald trump	selección colombia
selección colombia	presidente petro	donald trump	presidente petro	américa latina	luis díaz
atlético nacional	corte suprema	dólar hoy	selección colombia	inteligencia artificial	james rodríguez
miguel uribe	presidente gustavo	miguel uribe	presidente gustavo	gustavo petro	estados unidos

Tabla 7. Bigramas más distintivos por medio (corte Duque; por cada 1 000 titulares).

Medio	Bigramas
Blu Radio	programa completo (53,2), blu programa (19,2), voz populi (13,3)
El Tiempo	caricatura matador (7,0), selección colombia (6,6), editorial tiempo (6,1)
La República	dólar petróleo (7,2), américa latina (6,5), reino unido (6,0)
Caracol	video noticias (9,7), pico placa (6,6), claudia lópez (5,9)
RCN	pico placa (11,8), emisión martes (8,2), emisión miércoles (8,0)

Lo observado:

- **Agenda política común en el corte Petro:** «gustavo petro», «estados unidos» y «donald trump» están entre los primeros en casi todos los medios.
- **Perfiles temáticos:** La República es económica («petróleo hoy», «banco central»), RCN deportiva («selección colombia», «luis díaz») y Cambio política y judicial («álvaro uribe», «corte suprema»).
- **El formato pesa más que el tema en el corte Duque,** donde no se separó el contenido de servicio: los bigramas más distintivos

son programas (Blu Radio), emisiones (RCN), caricatura y editorial (El Tiempo). Solo La República destaca por un tema.

- **Servicio no capturado por las reglas:** «pico y placa» y «precio del dólar» aparecen en ambos cortes. Es un ajuste pendiente del clasificador.

2.7. Coocurrencias

Se calcularon con información mutua puntual [10] a nivel de titular: qué palabras aparecen junto a un término más de lo esperable por azar.

Tabla 8. Palabras con mayor coocurrencia por término foco (corte Petro).

Foco	Coocurrentes
petro	alocución, desaprobación, retractarse
reforma	subcomisión, pensional, tributaria, hundida, agraria, ponencia
eln	garante, cerac, diálogos, negociadores, arauca
paz	firmante, comisionado, facilitador, gestores
salud	savia, asmet, mental, reproductiva, magisterio
elecciones	atípicas, legislativas, presidenciales, anticipadas

Lo observado:

- **Corte Petro:** «reforma» se asocia con su trámite legislativo (subcomisión, ponencia, hundida) y «eln» con los diálogos y con un territorio (Arauca).
 - **Corte Duque, coocurrencias con cada tema frente a los demás medios** (log-odds descriptivo, sin prueba de significancia):
 - En **reforma tributaria**, La República asocia el tema con *pib*, *censo*, *méxico* y *chile*, y El Tiempo con *columna* y *entrevista*.
 - En **conflicto armado**, RCN coocurre con *detienen*, *vínculos* y *prontuario*, y Caracol con *video*, *mataron* y *magnicidio*.
- Es vocabulario policial y de sucesos: una hipótesis concreta para el análisis de encuadre.

2.8. Cobertura temática (corte Duque)

Para cada tema se midió qué porcentaje de los titulares de cada medio contiene sus palabras clave, con intervalo de Wilson [11]. Las diferencias se probaron con χ^2 , con corrección de Holm [12] para las tres pruebas y la V de Cramér como tamaño de efecto.

Tabla 9. Porcentaje de titulares con palabras clave de cada tema (5 medios, N = 707 455).

Medio	Reforma tributaria	Conflicto armado	Corrupción
Blu Radio	0,42	1,97	0,67
El Tiempo	0,41	1,33	0,44
La República	1,08	0,10	0,35
Caracol	0,32	1,66	0,51
RCN	0,37	1,97	0,53
χ^2	819,4	1 702,3	162,2
p (Holm)	< 10 ⁻¹⁷⁵	< 10 ⁻³⁰⁰	< 10 ⁻³³
V de Cramér	0,034	0,049	0,015




Figura 5. Porcentaje de titulares con palabras clave por tema y medio (corte Duque).

Lo observado:

- **Diferencias significativas pero pequeñas:** las tres son significativas, con efectos muy pequeños (V de 0,015 a 0,049). Con casi 708 000 titulares, un valor p diminuto es esperable.
- **Perfiles por tema:** La República tiene la mayor tasa de reforma tributaria (1,08 %) y la menor de conflicto armado (0,10 %); Blu Radio y RCN, la mayor de conflicto (1,97 %).
- **En ventanas acotadas alrededor de hechos concretos la escala cambia:**
 - **Reforma tributaria y paro de 2021:** el tema ocupó el 5,3 % de los titulares de El Tiempo y Caracol, frente al 1,3 % de La República.
 - **Bombardero con menores de 2019:** de 2,6 % (Caracol) a 0,1 % (La República).
 - **Centros Poblados (2021):** de 1,9 % (Caracol) a 0,6 % (La República).

Un mismo tema, distintos énfasis. El 15 de abril de 2021, día de la radicación de la reforma tributaria, cada medio destacó un aspecto distinto (Tabla 10).

Tabla 10. Titulares reales del 15 de abril de 2021 sobre la reforma tributaria (se restituyeron tildes y puntuación).

Medio	Titular	Énfasis
El Tiempo	«Reforma tributaria: ¿quién debe pagar el impuesto a la riqueza?»	Quién paga
Blu Radio	«Reforma tributaria: conozca el listado de productos que están excluidos del IVA»	Servicio al lector
La República	«Los impuestos a los más ricos que tiene la reforma tributaria»	Impuestos a altos ingresos
Caracol	«Subir IVA al café, sal, azúcar y chocolate: crece preocupación en Congreso sobre reforma tributaria»	Costo y reacción política
RCN	«Así impactará la reforma tributaria el bolsillo de los colombianos»	Impacto en el hogar

Son diferencias léxicas y de énfasis en titulares; no demuestran por sí solas encuadre ni postura editorial.

2.9. Modelado de tópicos (LDA, corte Duque)

Se entrenó LDA [13] sobre los 706 083 titulares con vocabulario útil, probando $K = 3, 5, 7, 10$ y 15 . $K = 5$ obtuvo la mayor coherencia c_v [14] (0,360, frente a 0,339 con $K = 7$). No se midió la variabilidad entre semillas.

Tabla 11. Términos principales de cada tópico (verificados contra el modelo guardado). Las lecturas entre paréntesis son orientativas.

Tópico	Términos principales	Lectura
--------	----------------------	---------

Tópico	Términos principales	Lectura
T0	emisión, bogotá, martes, jueves, nacional, miércoles	Programación y emisiones
T1	covid, colombia, bogotá, años, coronavirus, personas	Pandemia y noticias generales
T2	colombia, duque, ucrania, unidos, presidente, rusia, venezuela	Política nacional e internacional
T3	colombia, así, video, pico, placa, américa, mundial	Movilidad, video y deportes
T4	petro, gustavo, luis, caso, díaz, covid, fiscalía	Actores y casos judiciales




Figura 6. Distribución del tópico dominante por medio (corte Duque).

Lo observado:

- **Los perfiles no son uniformes** ($\chi^2 = 9887$; $V = 0,059$): Caracol concentra el 36,9 % de sus titulares en T1 (pandemia), El Tiempo el 27,8 % en T3 y La República tiene la mayor proporción de T2 (21,5 %) (Figura 6).
- **Blu Radio y RCN son los más parecidos** (distancia de Jensen-Shannon [15] 0,018); Caracol (0,074) y La República (0,067) son los más alejados del perfil promedio.
- **Los tópicos mezclan agenda y formato** (T0 son emisiones): con titulares de unas 7 palabras, LDA captura tanto el tipo de producto como el tema. Son patrones automáticos sin validación humana.
- **Confianza de las asignaciones:** el 3,7 % de los titulares asignados tiene una confianza menor de 0,3.

III. CONJUNTO DE DATOS MEDIDO

Corte Petro (carpeta entrega2/). Un Parquet por medio (dataset/corpus_<medio>.parquet, todos de menos de 100 MB), una muestra legible en Excel (dataset/muestra.csv, 2 400 filas), el diccionario de datos (DICCIONARIO_DATOS.md) y las tablas de métricas (metricas/). Cada fila es un titular con estas variables:

- **Identificación:** id, source_id, medio, government_id, published_date, mes, url.
 - **Texto:** title, title_source, titulo_limpio, tokens, tokens_contenido.
 - **Longitudes:** n_caracteres, n_tokens, n_tokens_contenido.
 - **Categorías iniciales:** tipo_contenido, temas, temas_padre, actores, tipos_actor.
- Corte Duque** (carpeta entrega2/resultados/):
- document_topics.parquet (708 768 filas): article_id, source_id, published_date, year, date_precision, title_source, dominant_topic y topic_confidence.

- diversidad_documentos.parquet: num_tokens, ttr, mstr_titulo y yule_k por titular.
- Tablas de frecuencias, bigramas, trigramas, diversidad, cobertura temática, casos temporales con URL y la grilla LDA.

El titular limpio y los tokens del corte Duque se agregan con exportar_dataset_medido.py, que usa la misma tokenización del análisis. Una auditoría reproducible aprobó 46 verificaciones de integridad sobre este corte.

IV. REPRESENTACIÓN DE LOS TEXTOS

Tabla 12. Representaciones comparadas (corte Petro, 916 452 noticias).

Técnica	Dimensiones	Densidad	Para qué sirve
Bolsa de palabras (BoW)	44 204	0,017 %	Línea base interpretable: qué palabras se eligen
TF-IDF (unigramas y bigramas)	197 921	0,005 %	Destacar lo específico; encontrar el mismo hecho
LSA (SVD sobre TF-IDF)	100	100 %	Agrupar palabras relacionadas; visualizar
FastText (entrenado en el corpus)	100	100 %	Similitud semántica; palabras raras y variantes

BoW y TF-IDF [16] son interpretables: el sesgo por selección léxica se expresa justamente en qué palabras se eligen [17]. Pero los titulares son tan cortos que cada uno activa unas 7 de las 44 204 dimensiones, y dos titulares sobre lo mismo con palabras distintas no se parecen. Por eso se complementan con representaciones densas: LSA [18] y FastText [19].

Ejemplo de transformación (corte Petro). El titular de Cambio «Las razones por las que pidieron a Suecia investigar la compra de los aviones Gripen por parte de Colombia» queda como:

- **BoW:** un 1 en cada una de sus nueve palabras de contenido.
- **TF-IDF:** los pesos más altos son para *investigar compra* (0,40), *parte colombia* (0,35) y *aviones gripen* (0,31).
- **FastText:** un vector denso de 100 dimensiones.

El mismo hecho en distintos medios. Con TF-IDF, la similitud del coseno restringida a otros medios y a ± 2 días recupera las coberturas de un mismo hecho. Para una consulta sobre la reforma pensional (octubre de 2023), las coberturas más parecidas son de cuatro medios y tratan el mismo hecho: el aval fiscal de Hacienda (Tabla 13).

Tabla 13. Coberturas más similares a una consulta sobre la reforma pensional (corte Petro).

Medio	Similitud	Titular
RCN	0,43	Reforma pensional: Ministerio de Hacienda dio el aval fiscal al proyecto en segundo debate
Blu Radio	0,43	Reforma pensional sería completamente financiable hasta el...: Minhacienda
La República	0,38	El Minhacienda le dio el aval fiscal a la ponencia para segundo debate de la pensional
Caracol	0,26	Reforma pensional: ¿cuál sería el impacto fiscal de este proyecto?

Medio	Similitud	Titular
Caracol	0,25	Minhacienda da luz verde al proyecto, pero reconoce que nuevo sistema valdrá más
Blu Radio	0,24	La reforma pensional crea una deuda impagable: Asofondos

Sobre el mismo hecho, un medio destaca el aval, otro la sostenibilidad («completamente financiable»), otro el costo («valdrá más») y otro la voz crítica de un gremio («deuda impagable»). En el corte Duque ocurre lo mismo: el 15 de abril de 2021, «Reforma tributaria: Duque pide al Congreso apoyo para aprobarla» (Blu Radio) y «Reforma tributaria ya fue radicada ante el Congreso de la República» (RCN) son los dos titulares más parecidos del día (coseno 0,62).




Figura 7. Proyección t-SNE de la representación LSA de 3 000 noticias, por tema (izquierda) y por medio (derecha).

Lo observado:

- **La representación agrupa por tema, no por medio** (Figura 7, proyección t-SNE [20]). Captura de qué se habla y no quién lo publica, que es lo necesario para comparar cómo cuentan los medios un mismo tema.
- **Excepción:** un grupo de «medio ambiente» compuesto solo por titulares de RCN, que debe verificarse.
- **FastText captura relaciones semánticas del período** (Tabla 14).
- **Los tópicos LDA son poco informativos** para clasificar un titular individual: con tan pocas palabras, reparten la probabilidad entre varios tópicos.

Tabla 14. Vecinos más cercanos en FastText (corte Petro).

Palabra	Vecinos (coseno)
eln	disidencias (0,79), farc (0,75), guerrilla (0,74)
paz	diálogos (0,70), total (0,69), timochenko (0,65)
inflación	desinflación (0,92), estanflación (0,91)
corrupción	anticorrupción (0,88), escándalo (0,76)
uribe	turbay (0,86), miguel (0,84), álvaro (0,80)

Elección. TF-IDF será la representación principal para el análisis léxico y para encontrar el mismo hecho; FastText aportará la semántica del vocabulario; y los embeddings contextuales (Sentence-BERT [21]) se usarán para agrupar coberturas por evento, donde la paráfrasis entre medios es la norma.

V. PROPUESTA METODOLÓGICA

5.1. Enfoque

El sesgo se medirá en cuatro dimensiones [17], cada una con su propia tarea:

- **A:** qué palabras se eligen.
- **B:** a quién se cita.

- **C:** qué se enfatiza u omite.
- **D:** cómo se enmarca el hecho [1].

Como el tono emocional depende del hecho y el sesgo depende de cómo se cuenta, ningún medio se comparará con otro fuera de un mismo evento, y la carga emocional será una variable de control.




Figura 8. Arquitectura de la propuesta.

Tabla 15. Enfoque de modelado por dimensión.

Dimensión	Tipo de modelado	Datos	Métrica
A · Léxico	Clasificación supervisada de subjetividad	Titular y primer párrafo	Precisión, recall, F1
B · Fuentes	Extracción de citas + detección de postura	Oraciones con cita	F1 macro; Gini de voces
C · Cobertura	Modelado dinámico de tópicos (no supervisado)	Corpus completo, por trimestre	Jensen-Shannon; coherencia
D · Encuadre	Clasificación supervisada multietiqueta	Titular y primer párrafo, por evento	F1 macro y micro
Transversal	Agrupamiento por evento	Titulares en ±2 días	ARI, pureza

5.2. Justificación por dimensión

- **A.** La subjetividad está en la oración. Existe un corpus anotado de sesgo en prensa en español, el MBBMD [22], para ajustar modelos antes de anotar el corpus propio.
- **B.** Citar directamente a un actor lo legitima; relatarlo lo distancia. La postura no es lo mismo que el sentimiento [23]. Se explorará el aprendizaje en contexto guiado por criterios periodísticos [24].
- **C.** El énfasis y la omisión solo se ven en el agregado y en el tiempo. El LDA de esta entrega es la línea base; se compararán el modelo dinámico de tópicos [25] y BERTopic [26], este último más adecuado para textos cortos.
- **D.** Los encuadres se definirán en pares por tipo de hecho: criminalización o reivindicación en protestas; bélico o diálogo en el conflicto armado [27]; crisis o logro en la gestión del gobierno. Los LLM detectan encuadres de forma inconsistente [28], así que se compararán con clasificadores entrenados.

5.3. Modelos a comparar y criterios

En A, B y D se compararán tres familias:

1. Una línea base clásica (TF-IDF con regresión logística y lexicón).
2. Un *transformer* en español ajustado: BETO [29] o MarIA [30].
3. Un LLM, con instrucciones o ajustado con LoRA [31].

La comparación central (pregunta de investigación 3) es una **cascada de clasificadores especializados frente a un LLM ajustado**.

Tabla 16. Criterios de comparación.

Criterio	Cómo se mide
Desempeño	F1 macro y micro con intervalos

Criterio	Cómo se mide
	<i>bootstrap</i> del 95 %
Robustez contrafactual	Cambio de la predicción al intercambiar nombres de actores y medios [22], [32]
Carga emocional	Desempeño estratificado por intensidad emocional [33]
Robustez temporal	Entrenar en un gobierno y evaluar en el otro
Interpretabilidad	Evidencia textual de cada predicción
Costo	Tiempo y hardware por cada 1 000 textos

Las particiones se harán por evento, para que un mismo hecho no quede en entrenamiento y prueba. Si dos modelos no difieren en F1, se elegirá el más robusto y económico.

5.4. Validación y próximos pasos

Cada etapa debe producir evidencia antes de comparar encuadres:

1. **Preparar datos:** recuperar el texto completo de una muestra, revisar fechas y duplicados, y formar muestras comparables por período.
2. **Validar medidas:** anotar 50–100 artículos por tema, por 2–3 personas, para evaluar las palabras clave y los encuadres. El acuerdo se medirá con el alfa de Krippendorff [34], y se conservarán las etiquetas de todos los anotadores (anotación perspectivista [22]).
3. **Repetir y comparar:** probar LDA con 10 o más semillas, procesar ambos cortes con el mismo pipeline y comparar Duque y Petro.

Relación con las preguntas de investigación:

- **PI 1** (¿cambian tópicos y encuadres según la concordancia con el gobierno?): ahora es abordable con dos gobiernos y los mismos medios.
- **PI 2** (¿coinciden los verificadores?) [35]: requiere recolectar La Silla Vacía, Colombiacheck y AFP Factual, o reformularse.
- **PI 3** (cascada frente a LLM): se responde con la Sección 5.3.

VI. CONCLUSIONES

Tabla 17. Lo que se puede y lo que no se puede afirmar con esta entrega.

Afirmación descartada	Lectura correcta
Sesgo editorial confirmado	Diferencias observables entre medios; correlaciones, no causalidad
La República es «35 % más diversa»	Su TTR es cerca de un 7 % menor; su MSTTR es el más alto
Agenda común	Perfiles de tópicos distintos ($V = 0,059$), aunque con efecto pequeño
Cambio tiene cobertura distinta en el corte Duque	Seis días de datos: no es comparable
Zipf prueba lenguaje «puro»	Correlación descriptiva
Tópicos LDA validados	Patrones automáticos sin etiquetado humano

Lo observado:

- **Cobertura y lenguaje:** los medios difieren en cobertura temática, diversidad léxica y perfiles de tópicos, con efectos pequeños.
- **Formatos:** buena parte de las diferencias léxicas proviene de los formatos de cada portal; separarlos es un requisito antes de hablar de encuadre.
- **Mismo hecho, distinto énfasis:** las representaciones encuentran la cobertura de un mismo hecho en distintos medios, y en esos casos

ya aparecen énfasis distintos (aval frente a costo; impuestos a los ricos frente al bolsillo de los hogares).

Limitaciones:

- **Titulares reconstruidos** desde la URL, sin cuerpo ni comillas.
- **Fechas** con precisión de mes en 38 621 registros.
- **32 368 titulares repetidos.**
- **Pipelines distintos** entre cortes.
- **Sin anotación humana** de temas, tópicos ni encuadres.

REFERENCIAS

- [1] R. M. Entman, «Framing: Toward Clarification of a Fractured Paradigm», *Journal of Communication*, vol. 43, n.º 4, pp. 51-58, 1993.
- [2] F. Hamborg, «Media Bias, the Social Sciences, and NLP: Automating Frame Analyses to Identify Bias by Word Choice and Labeling», en *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics: Student Research Workshop*, Association for Computational Linguistics, 2020. Disponible en: <https://aclanthology.org/2020.acl-srw.12/>
- [3] J. S. Wang *et al.*, «Media Bias Detector: Designing and Implementing a Tool for Real-Time Selection and Framing Bias Analysis in News Coverage», en *Proceedings of the 2025 CHI Conference on Human Factors in Computing Systems*, ACM, 2025. doi: 10.1145/3706598.3713716.
- [4] J. Grimmer y B. M. Stewart, «Text as Data: The Promise and Pitfalls of Automatic Content Analysis Methods for Political Texts», *Political Analysis*, vol. 21, n.º 3, pp. 267-297, 2013.
- [5] G. K. Zipf, *Human Behavior and the Principle of Least Effort*. Addison-Wesley, 1949.
- [6] A. Clauset, C. R. Shalizi, y M. E. J. Newman, «Power-Law Distributions in Empirical Data», *SIAM Review*, vol. 51, n.º 4, pp. 661-703, 2009.
- [7] M. A. Covington y J. D. McFall, «Cutting the Gordian Knot: The Moving-Average Type-Token Ratio (MATTR)», *Journal of Quantitative Linguistics*, vol. 17, n.º 2, pp. 94-100, 2010.
- [8] P. M. McCarthy y S. Jarvis, «MTLD, voed-D, and HD-D: A Validation Study of Sophisticated Approaches to Lexical Diversity Assessment», *Behavior Research Methods*, vol. 42, n.º 2, pp. 381-392, 2010.
- [9] G. U. Yule, *The Statistical Study of Literary Vocabulary*. Cambridge University Press, 1944.
- [10] K. W. Church y P. Hanks, «Word Association Norms, Mutual Information, and Lexicography», *Computational Linguistics*, vol. 16, n.º 1, pp. 22-29, 1990.
- [11] E. B. Wilson, «Probable Inference, the Law of Succession, and Statistical Inference», *Journal of the American Statistical Association*, vol. 22, n.º 158, pp. 209-212, 1927.
- [12] S. Holm, «A Simple Sequentially Rejective Multiple Test Procedure», *Scandinavian Journal of Statistics*, vol. 6, n.º 2, pp. 65-70, 1979.
- [13] D. M. Blei, A. Y. Ng, y M. I. Jordan, «Latent Dirichlet Allocation», *Journal of Machine Learning Research*, vol. 3, pp. 993-1022, 2003.
- [14] M. Röder, A. Both, y A. Hinneburg, «Exploring the Space of Topic Coherence Measures», en *Proceedings of the Eighth ACM International Conference on Web Search and Data Mining (WSDM)*, 2015, pp. 399-408.
- [15] J. Lin, «Divergence Measures Based on the Shannon Entropy», *IEEE Transactions on Information Theory*, vol. 37, n.º 1, pp. 145-151, 1991.
- [16] K. Spärck Jones, «A Statistical Interpretation of Term Specificity and its Application in Retrieval», *Journal of Documentation*, vol. 28, n.º 1, pp. 11-21, 1972.
- [17] F. Hamborg, K. Donnay, y B. Gipp, «Automated Identification of Media Bias in News Articles: An Interdisciplinary Literature Review», *International Journal on Digital Libraries*, vol. 20, n.º 4, pp. 391-415, 2019.
- [18] S. Deerwester, S. T. Dumais, G. W. Furnas, T. K. Landauer, y R. Harshman, «Indexing by Latent Semantic Analysis», *Journal of the American Society for Information Science*, vol. 41, n.º 6, pp. 391-407, 1990.
- [19] P. Bojanowski, E. Grave, A. Joulin, y T. Mikolov, «Enriching Word Vectors with Subword Information», *Transactions of the Association for Computational Linguistics*, vol. 5, pp. 135-146, 2017.
- [20] L. van der Maaten y G. Hinton, «Visualizing Data using t-SNE», *Journal of Machine Learning Research*, vol. 9, pp. 2579-2605, 2008.
- [21] N. Reimers y I. Gurevych, «Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks», en *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing (EMNLP-IJCNLP)*, 2019, pp. 3982-3992.
- [22] F.-J. Rodrigo-Ginés, J. Carrillo-de-Albornoz, y L. Plaza, «Media Bias Bias-Mitigated Dataset (MBMD): A Hierarchical, Perspectivist, and Counterfactually-Augmented Corpus for Bias Detection in Spanish News», *Procesamiento del Lenguaje Natural*, vol. 76, pp. 53-64, 2026.
- [23] M. Burnham, «Stance Detection: A Practical Guide to Classifying Political Beliefs in Text», *Political Science Research and Methods*, vol. 13, n.º 3, pp. 611-628, 2024.
- [24] D. Lee, J. Choi, J. Han, y K. Park, «Journalism-Guided Agentic In-Context Learning for News Stance Detection». arXiv:2507.11049v2, 2025.
- [25] D. M. Blei y J. D. Lafferty, «Dynamic Topic Models», en *Proceedings of the 23rd International Conference on Machine Learning (ICML)*, 2006, pp. 113-120.
- [26] M. Grootendorst, «BERTopic: Neural Topic Modeling with a Class-Based TF-IDF Procedure». arXiv:2203.05794, 2022.
- [27] A.-L. Dießelmann y A. Hetzer, «Encuadres visuales en las fotografías de prensa del proceso de paz en Colombia», *Universitas Humanística*, vol. 88, pp. 1-36, 2019.
- [28] V. Pastorino, J. A. Sivakumar, y N. S. Moosavi, «Decoding News Narratives: A Critical Analysis of Large Language Models in Framing Detection», en *Proceedings of the 3rd Workshop on Natural Language Processing for Political Sciences (PoliticalNLP)*, 2026, pp. 17-28.
- [29] J. Cañete, G. Chaperon, R. Fuentes, J.-H. Ho, H. Kang, y J. Pérez, «Spanish Pre-Trained BERT Model and Evaluation Data», en *PML4DC Workshop at ICLR*, 2020.
- [30] A. Gutiérrez-Fandiño *et al.*, «MarIA: Spanish Language Models», *Procesamiento del Lenguaje Natural*, vol. 68, pp. 39-60, 2022.
- [31] E. J. Hu *et al.*, «LoRA: Low-Rank Adaptation of Large Language Models», en *International Conference on Learning Representations (ICLR)*, 2022.
- [32] K. Salas-Jiménez, S.-L. Ojeda-Trueba, G. Bel-Enguix, E. Lee-Romero, y F. F. López-Ponce, «An LLM-Based Methodology for the Automatic Detection of Bias in the DuoWikiBias Corpus», *Frontiers in Artificial Intelligence*, vol. 9, p. 1791624, 2026.
- [33] Ó. Moreno-Martínez, «El círculo vicioso de la expresión violenta y la polarización ideológico-afectiva en tiempos de COVID-19», *Signo y Pensamiento*, vol. 42, pp. 1-18, 2023.
- [34] K. Krippendorff, *Content Analysis: An Introduction to Its Methodology*, 2.ª ed. Sage, 2004.
- [35] C. Rodríguez-Pérez, «Desinformación online y fact-checking en entornos de polarización social: el periodismo de verificación de Colombiacheck, La Silla Vacía y AFP durante la huelga nacional del 21N en Colombia», *Estudios sobre el Mensaje Periodístico*, vol. 27, n.º 2, pp. 623-637, 2021.