

Detección de sesgo mediático mediante análisis de framing: EDA avanzado y representación de titulares de prensa colombiana

Abel Albuez Sanchez, Kelly Joane Leon Torres, Juan Camilo Torres Peña, Jesús David Romero Melo

Maestría en Ingeniería de Sistemas y Computación, Pontificia Universidad Javeriana, Bogotá D.C., Colombia

Procesamiento de Lenguaje Natural, 2026 — Entrega 2

Resumen

Esta entrega reemplaza el corpus ficticio de la Entrega 1 por un corpus real de 984 590 titulares publicados por seis medios colombianos durante el gobierno de Gustavo Petro (agosto de 2022 a julio de 2026). Se describen las decisiones que hicieron comparable el corpus, se separa el contenido de servicio de las noticias, se integran un tesauruso temático y una ontología de actores, y se reportan medidas de diversidad léxica, n-gramas, colocaciones y co-ocurrencias. Para cada técnica se expone su fundamento: qué mide, cómo se calcula y por qué es adecuada para titulares de prensa. Finalmente se comparan cuatro representaciones del texto (BoW, TF-IDF, LSA y FastText) y se muestra que permiten recuperar la cobertura de un mismo hecho en distintos medios, paso previo al análisis de framing.

Index Terms— media bias, framing analysis, exploratory data analysis, text representation, Spanish NLP, Colombian news.

I. CORRECCIONES RESPECTO A LA ENTREGA 1

La Entrega 1 documentó la idea, el estado del arte y un prototipo probado sobre un evento con tres artículos de medios ficticios; el corpus histórico estaba en construcción y no se reportaron cifras. La Tabla 1 resume los ajustes y sus razones.

1.1. Construcción del corpus

El servicio `news-retrieval` recorre los sitemaps que cada medio publica para buscadores, mes a mes y a una petición por segundo. Cada mes de cada medio se registra como un bloque con estado completado o fallido, lo que permite reanudar la recolección y auditar su cobertura. Los seis medios incluidos completaron los 48 meses de la ventana; El Espectador, Semana y W Radio quedaron excluidos porque sus feeds solo alcanzan meses recientes.

Ningún medio publica el titular en sus sitemaps históricos, por lo que el titular se reconstruye desde la URL (*slug*):

`.../congreso-aprueba-reforma-pensional-123` se convierte en «Congreso aprueba reforma pensional». La reconstrucción pierde tildes, comillas y puntuación, y el titular puede diferir del publicado si el medio lo cambió o redactó el *slug* para buscadores. Cada fila conserva su procedencia (`title_source`), y la herramienta `validar-titulares` compara una muestra aleatoria con el titular publicado.

II. ANÁLISIS EXPLORATORIO AVANZADO

2.1. Preprocesamiento

Fundamento. Antes de contar palabras hay que decidir qué cuenta como la «misma» palabra. Cada decisión de preprocesamiento es una hipótesis sobre qué variación es ruido y cuál es señal [1]. En este corpus la hipótesis central es que la presencia o ausencia de tildes, mayúsculas y puntuación es ruido: el 100 % de los titulares se reconstruyó desde la URL y ya llega sin esos rasgos. Normalizar todos los titulares a la misma forma evita que una diferencia de procedencia parezca una diferencia entre medios.

- **Normalización Unicode.** Cada carácter se descompone en su forma canónica (NFKD) y se eliminan las marcas diacríticas combinantes. Así «Nariño», «Narino» y «NARIÑO» quedan como *narino*. Luego se pasa a minúsculas y se reemplaza todo lo que no sea letra o dígito por un espacio.
- **Tokenización.** Una expresión regular separa secuencias de letras y de dígitos. En titulares no hace falta segmentar oraciones: cada titular es, en la práctica, una sola oración.
- **Palabras vacías (*stopwords*).** La ley de Zipf [2] establece que la frecuencia de una palabra es aproximadamente inversa a su rango: unas pocas palabras funcionales (*de*, *la*, *que*) concentran gran parte de los tokens y aportan poco contenido. Se eliminan para los conteos de vocabulario, pero se conservan dentro de los n-gramas (Sección 2.5).

Tabla 1: Correcciones y modificaciones respecto a la Entrega 1.

Aspecto	Entrega 1	Entrega 2	Razón
Corpus	Un evento, tres medios ficticios (<code>corpus_ejemplo.json</code>).	984 590 titulares reales de seis medios, 48 meses.	El ejemplo servía para probar el prototipo, no para describir medios reales.
Medios	Diez catalogados; recolector para cinco.	Dos recolectores nuevos (feeds Arc e índices de sitemap): nueve recolectables, seis comparables.	El Espectador, Semana y W Radio no cubren la ventana; criterio: ≥ 90 % de meses completos.
Ventana	2006–2026.	Gobierno Petro: 2022-08 a 2026-07.	Única ventana con seis o más medios; un solo gobierno controla la agenda como variable de confusión.
Unidad	Texto completo; medidas por oración.	Titular.	El cuerpo no es comparable (en el piloto: 99 % en El Tiempo frente a 15 % en Blu Radio); el titular cubre $\geq 99,8$ % de las URLs.
Limpieza	Normalizar espacios; conservar términos originales.	Minúsculas, sin tildes ni puntuación; tokens de contenido de tres o más letras.	El titular se reconstruye desde la URL y ya llega sin tildes; normalizar todo evita confundir procedencia con diferencia entre medios.
Contenido	—	Clasificación noticia / servicio (lotería, horóscopo, opinión, multimedia).	En una primera corrida, «sorteo» o «chance» dominaban las frecuencias de algunos medios.
Medidas	Previstas sin cifras; estilo evaluado por un LLM.	Longitudes, TTR, MATTR, MTLD, K de Yule, n-gramas, PMI y coocurrencias.	Pendiente explícito de la Entrega 1.
Recursos léxicos	—	Tesoro temático y ontología de actores.	Describen el corpus por temas y tipos de actor.
Evento	<code>evento_id</code> manual.	Recuperación del mismo hecho por similitud de representaciones (Sección IV).	Asignar eventos a mano es inviable con cerca de un millón de titulares.

- **Longitud mínima.** Se descartan los tokens de menos de tres letras. Elimina fragmentos de la URL (`rg`, `so`) y restos como `us` (de US\$), y conserva siglas relevantes (`eln`, `eps`, `cne`).
- **Tipo de contenido.** Reglas sobre el titular y la ruta de la URL (`config/tipos_contenido.yaml`) separan noticias de contenido de servicio: lotería, horóscopo, opinión y multimedia.

2.2. Descripción del corpus

La Tabla 2 y la Figura 1 describen el corpus. El Tiempo aporta el 41 % de los titulares y Cambio el 4,5 %. El volumen mensual es estable en toda la ventana; el primer mes es menor porque el gobierno comienza el 7 de agosto de 2022. Los titulares de Caracol y Blu Radio son los más largos (15–16 palabras) y los de Cambio, La República y RCN los más breves (11–12).

El contenido de servicio representa el 6,9 % del corpus, pero se concentra en pocos medios: en Blu Radio llega al 14,9 % (lotería 10,0 % y multimedia 4,1 %), en El Tiempo al 6,6 % (opinión 4,8 %) y en Cambio es prácticamente




Figura 1: Volumen mensual de titulares por medio.

nulo. Sin esta separación, las frecuencias describirían la oferta de productos de cada portal y no su manera de informar. Desde aquí, el análisis usa las 916 452 noticias.

2.3. Recursos léxicos: tesauros y ontologías

Fundamento

Un recurso léxico representa conocimiento sobre las palabras y sobre aquello a lo que se refieren. Interesan aquí

Tabla 2: Descripción del corpus por medio (2022-08 a 2026-07). *Servicio:* lotería, horóscopo, opinión y multimedia. *Con tema:* porcentaje de noticias con al menos un tema del tesauro.

Medio	Titulares	Por mes	Palabras	Caracteres	% servicio	Noticias	% con tema
El Tiempo	406 313	8 465	14,1	83,7	6,6	379 578	32,2
Blu Radio	203 738	4 245	15,0	83,5	14,9	173 300	32,3
RCN	130 180	2 712	12,2	72,8	2,7	126 613	28,8
La República	105 876	2 206	11,8	70,7	1,5	104 267	26,9
Caracol	94 108	1 961	15,9	86,8	6,1	88 386	27,8
Cambio	44 375	924	11,3	69,1	0,2	44 308	40,1
Total	984 590	20 512			6,9	916 452	

tres tipos, de menor a mayor estructura:

- **Vocabulario controlado:** lista de términos autorizados para describir algo, sin relaciones entre ellos.
- **Tesauro:** organiza *conceptos*, cada uno con un término preferente y términos alternativos (sinónimos, variantes), y los relaciona mediante relaciones jerárquicas (término genérico, BT, y específico, NT) y asociativas (relacionado, RT). Su referencia normativa es la ISO 25964 [3], y en la web se expresa con SKOS [4], que modela los conceptos como `skos:Concept` unidos por `skos:broader` y `skos:narrower`, con etiquetas `skos:prefLabel` y `skos:altLabel`.
- **Ontología:** según la definición clásica de Gruber, una «especificación explícita de una conceptualización» [5]. Además de jerarquías, distingue *clases* (tipos de entidad) de *instancias* (entidades concretas), y puede declarar propiedades y restricciones entre ellas [6].

La diferencia práctica es que un tesauro organiza *temas* (de qué trata un texto), mientras que una ontología organiza *entidades* (quién o qué aparece en él).

Aplicar estos recursos a un corpus es un *método de diccionario*: un texto recibe una categoría si contiene alguno de sus términos. Su ventaja es la transparencia, porque cada asignación se explica por el término que la produjo. Su riesgo es la validez, ya que un diccionario construido para un dominio puede fallar en otro; Grimmer y Stewart advierten que estos métodos deben validarse sobre el corpus concreto antes de interpretar sus resultados [7]. Por eso todos los recursos se versionan en el repositorio y cada asignación registra el término y el campo que la originaron.

Tesauro temático

El archivo `config/topics.yaml` es un tesauro de dos niveles: 7 conceptos generales y 35 específicos, con 209 términos de entrada en total. En términos de SKOS:

- Cada tema es un `skos:Concept` con su nombre como `prefLabel`.

- La relación tema general $\rightarrow$ subtema es `skos:narrower`. Por ejemplo, *Seguridad* $\rightarrow$ *Conflicto armado*, *Guerrillas*, *Narcotráfico*.
- Las palabras clave cumplen el papel de `altLabel`: son los puntos de entrada léxicos del concepto. Por ejemplo, *Guerrillas* se activa con *guerrilla*, *eln*, *farc*, *disidencias*.

Un titular recibe un subtema cuando alguna de sus palabras clave aparece como palabra completa (expresión regular con límites de palabra) en el titular, la ruta de la URL o la sección. El tema general se hereda por la relación jerárquica, y el etiquetado es multi-etiqueta. Los titulares sin ningún tema no se descartan: el tesauro cubre política, economía, seguridad, sociedad, justicia, relaciones internacionales y medio ambiente, y deja fuera por diseño deportes y entretenimiento.

Ontología de actores

El archivo `config/actores.yaml` es una ontología ligera con dos niveles (Tabla 3):

- **Clases:** 11 tipos de actor.
- **Instancias:** 51 actores.
- **Relación de pertenencia:** cada actor pertenece a una clase (equivale a `rdf:type`).
- **Lexicalizaciones:** 204 alias en total. Por ejemplo, *petro*, *gustavo petro* y *presidente petro* remiten a la instancia *Gustavo Petro*, de la clase *Gobierno nacional*.

Tres decisiones de diseño responden a la ambigüedad del lenguaje periodístico:

- **Precisión antes que cobertura.** Se excluyeron los alias con lecturas frecuentes ajenas al actor: «fiscal» sin más contexto aparece en «regla fiscal» y «déficit fiscal», y «galán» tiene usos comunes. Se perdió cobertura para evitar asignaciones falsas.
- **Análisis por clase.** Algunos alias son ambiguos entre instancias: «uribe» puede referirse a Álvaro o a

Tabla 3: Clases de la ontología de actores, con el número de instancias y ejemplos.

Clase	Inst.	Ejemplos de instancias
Gobierno nacional	6	Gustavo Petro, Francia Márquez, ministros
Oposición política	8	Álvaro Uribe, Centro Democrático
Congreso	2	Congreso, partidos tradicionales
Rama judicial y Fiscalía	6	Fiscalía, Corte Constitucional
Órganos de control	4	Procuraduría, Contraloría
Fuerza pública	2	Policía, Ejército
Grupos armados ilegales	4	ELN, disidencias, Clan del Golfo
Movimientos sociales	6	indígenas, sindicatos, campesinos
Gremios	6	ANDI, Fenalco, Fedegán
Gobiernos locales	3	alcaldes y gobernadores
Internacional	4	Estados Unidos, Donald Trump

Miguel Uribe. Ambos pertenecen a la misma clase, así que el análisis por clase es robusto a esa ambigüedad aunque la instancia no lo sea.

- **Anclaje temporal.** Los cargos corresponden a la ventana del corpus. Los alias genéricos («fiscal general», «ministro») no dependen de quién ocupe el cargo.

La ontología no se formalizó en OWL porque el análisis solo usa la jerarquía clase $\rightarrow$ instancia y las lexicalizaciones. Su estructura permite, más adelante, alinear cada instancia con un identificador de Wikidata y heredar sus propiedades, como el partido o el cargo con sus fechas.

El clasificador de tipos de contenido es, en cambio, un vocabulario controlado plano: cuatro categorías de servicio con sus términos y rutas de URL, sin jerarquía.

Resultados

Entre el 27 y el 40 % de las noticias contiene al menos un tema del tesoro. Política es el tema general más frecuente en todos los medios (Figura 2), y los perfiles difieren de forma marcada:

- **La República** es el único medio donde Economía supera el 3 % (8,6 %), y casi no cubre seguridad (0,7 % frente a 4,8–9,3 % en los demás).
- **Cambio** tiene la mayor proporción de Política (14,6 %) y Justicia (5,5 %).

En la ontología, Gustavo Petro es la instancia más mencionada en Blu Radio, Cambio y Caracol, y Estados Unidos en El Tiempo, La República y RCN. La clase *Gobierno*




Figura 2: Porcentaje de noticias por tema general del tesoro.

nacional aparece en el 10,3 % de las noticias de Cambio, frente a 3,8–6,9 % en los demás medios. Estas cifras son descriptivas: indican qué cubre cada medio, no cómo lo cubre.

2.4. Diversidad léxica

Fundamento. La diversidad léxica mide qué tan variado es el vocabulario de un texto: si un medio reutiliza las mismas palabras o recurre a un repertorio amplio. Sea N el número de tokens de una muestra, V el número de palabras distintas (tipos) y V_m el número de tipos que aparecen exactamente m veces. La medida más simple es la razón tipo/token, $TTR = V/N$. Su problema es que el vocabulario crece más despacio que el texto: la ley de Heaps [8] establece que $V \approx kN^\beta$, con $0 < \beta < 1$. Por eso el TTR disminuye con la longitud y dos textos de distinto tamaño no son comparables [9]. Se usaron cinco medidas que abordan ese problema de formas distintas:

- **Guiraud** [10]: $R = V/\sqrt{N}$, que corrige parcialmente el efecto del tamaño.
- **MATTR** [11]: el promedio del TTR en ventanas móviles de W tokens, $\text{MATTR} = \frac{1}{N-W+1} \sum_{i=1}^{N-W+1} \text{TTR}(t_i, \dots, t_{i+W-1})$. Como cada ventana tiene el mismo tamaño ($W = 500$), la medida no depende de la longitud total.
- **MTLD** [12]: recorre el texto y cuenta cuántos *factores* se completan, es decir, tramos en los que el TTR acumulado cae hasta 0,72. $\text{MTLD} = N/F$ es la longitud media de esos tramos: un valor alto indica que el vocabulario tarda más en repetirse. Se promedia el recorrido hacia adelante y hacia atrás, y el tramo final se cuenta como factor parcial.
- **K de Yule** [13]: $K = 10^4 \frac{\sum m^2 V_m - N}{N^2}$, que mide la probabilidad de que dos tokens tomados al azar sean la misma palabra. Un valor *menor* indica *mayor* diversidad, y en teoría no depende de N .
- **Proporción de hápax**: V_1/V , la fracción de palabras que aparecen una sola vez.

Aun así, para que la comparación sea justa, todas las medidas se calcularon sobre muestras del mismo tamaño:

Tabla 4: Diversidad léxica (media de cinco muestras de 200 000 tokens). K de Yule: menor es más diverso.

Medio	TTR	MATTR	MTLD	K Yule
Cambio	0,098	0,629	163,1	119,0
El Tiempo	0,102	0,625	158,1	119,8
RCN	0,085	0,624	168,3	117,9
La República	0,094	0,617	147,3	138,3
Blu Radio	0,089	0,585	130,3	117,6
Caracol	0,087	0,576	115,7	129,4

cinco muestras aleatorias de 200 000 tokens por medio, formadas concatenando titulares en orden aleatorio (Tabla 4; las desviaciones entre muestras no superan 0,001 en MATTR ni 1,8 en MTLD).

Se distinguen dos grupos. Cambio, El Tiempo, RCN y La República tienen MATTR entre 0,617 y 0,629, mientras que Blu Radio y Caracol quedan en 0,576–0,585 y tienen los MTLD más bajos. Esta menor diversidad persiste aun sin el contenido de servicio, y coincide con plantillas de titular recurrentes en esos medios («pico y placa en...», «quedó en video», «Mañanas Blu»). La República tiene el K de Yule más alto: concentra su vocabulario en términos económicos repetidos (dólar, precio, tasas).

2.5. N-gramas

Fundamento. Un n-grama es una secuencia de n palabras consecutivas. Los unigramas describen el vocabulario; los bigramas y trigramas capturan unidades que no se reducen a sus palabras sueltas: nombres compuestos (*gustavo petro*), términos (*reforma pensional*) y fórmulas recurrentes (*pico y placa*). Quitar las *stopwords* antes de formar n-gramas destruiría expresiones como *reforma a la salud*. Por eso los n-gramas se forman sobre la secuencia completa y solo se exige que no empiecen ni terminen en *stopword*: se conserva *reforma a la salud* y se descarta *de la reforma*. Las frecuencias se reportan por cada 10 000 noticias para comparar medios de distinto tamaño.

La Tabla 5 resume los más frecuentes. Cuatro patrones se repiten:

- **Vocabulario político común:** «gustavo petro», «presidente petro», «estados unidos» y «donald trump» están entre los primeros en casi todos los medios.
- **Perfil temático:** La República es económica («petróleo hoy», «banco central», «salario mínimo»), RCN es deportiva («selección colombia», «luis díaz», «liga betplay») y Cambio es política y judicial («álvaro uribe», «corte suprema», «pacto histórico»).
- **Autorreferencias del medio:** «mañanas blu», «noticias rcn», «emisión noticias».
- **Contenido de servicio no cubierto por las reglas:** «pico y placa» y «precio del dólar» encabezan

los trigramas de varios medios. Es un ajuste pendiente del clasificador.

2.6. Colocaciones

Fundamento. Una colocación es una combinación de palabras que aparece junta más de lo que predice el azar. La frecuencia bruta no las detecta, porque favorece combinaciones de palabras que ya son muy comunes por separado. La información mutua puntual [14] compara la probabilidad observada de la pareja con la esperada si las palabras fueran independientes:

$$\text{PMI}(x, y) = \log_2 \frac{P(x, y)}{P(x)P(y)}. \quad (1)$$

Un PMI de k indica que la pareja aparece 2^k veces más de lo esperado. El PMI sobrevalora los eventos raros (dos palabras que aparecen una sola vez, juntas, obtienen el máximo), por lo que se exigió una frecuencia mínima de 45 apariciones.

Resultados. Las colocaciones con mayor PMI son nombres propios («bankman fried», «btg pactual», «stormy daniels»). Es el comportamiento esperado: un nombre propio es la colocación más fuerte posible. El resultado es útil para ampliar la ontología con entidades que todavía no contiene.

2.7. Coocurrencias

Fundamento. La hipótesis distribucional sostiene que palabras que aparecen en contextos parecidos tienen significados parecidos [15], y Firth lo resumió diciendo que una palabra se conoce por la compañía que mantiene [16]. Aquí el contexto es el titular completo. Para un término foco f y otra palabra w , se calcula el PMI a nivel de titular:

$$\text{PMI}(f, w) = \log_2 \frac{n_{fw}/n}{(n_f/n)(n_w/n)}, \quad (2)$$

donde n es el número de titulares y n_f , n_w y n_{fw} son los titulares que contienen f , w o ambas. Se usa la presencia y no la frecuencia, porque una palabra rara vez se repite dentro de un titular. Con un mínimo de coocurrencias, el resultado describe el campo semántico del término en el período. La coocurrencia de clases de la ontología en un mismo titular se reporta además como matriz (pares de tipos de actor).

Resultados. La Tabla 6 muestra los términos con mayor PMI para seis focos. «Reforma» se asocia con su trámite legislativo («subcomisión», «ponencia», «hundida») y con sus variantes («pensional», «tributaria», «agraria»), y «eln», con los diálogos («garante», «negociadores») y con un territorio («arauca»).

III. CONJUNTO DE DATOS MEDIDO

El corpus se entrega preprocesado en la carpeta `entrega2/` del repositorio:

Tabla 5: Bigramas más frecuentes por medio (noticias; contenido de servicio excluido).

Blu Radio	Cambio	Caracol	El Tiempo	La República	RCN
mañanas blu	gustavo petro	estados unidos	estados unidos	estados unidos	noticias rcn
presidente petro	estados unidos	presidente petro	gustavo petro	petróleo hoy	emisión noticias
estados unidos	álvaro uribe	gustavo petro	donald trump	donald trump	selección colombia
selección colombia	presidente petro	donald trump	presidente petro	américa latina	luis díaz
atlético nacional	corte suprema	dólar hoy	selección colombia	inteligencia artificial	james rodríguez
miguel uribe	presidente gustavo	miguel uribe	presidente gustavo	gustavo petro	estados unidos
zona rural	corte constitucional	papa francisco	luis díaz	reino unido	atlético nacional
gustavo petro	conflicto armado	redes sociales	liga betplay	banco central	liga betplay

Tabla 6: Términos con mayor PMI de coocurrencia en el mismo titular.

Foco	Coocurrentes
petro	alocución, desaprobación, retractarse, alocuciones
reforma	subcomisión, pensional, tributaria, hundida, agraria, ponencia
eln	garante, cerac, diálogos, negociadores, arauca
paz	firmante, comisionado, facilitador, gestores, duradera
salud	savia, asmet, mental, reproductiva, magisterio
elecciones	atípicas, legislativas, presidenciales, anticipadas

- **dataset/corpus_<medio>.parquet:** un archivo por medio, cada uno por debajo del límite de 100 MB de GitHub.
- **dataset/muestra.csv:** 2 400 filas legibles en Excel.
- **DICCIONARIO_DATOS.md:** descripción de cada columna.
- **metricas/:** las tablas de esta sección.

Cada fila es un titular con las siguientes variables:

- **Identificación:** id, source_id, medio, government_id, published_date, mes, url, section.
- **Texto:** titular original (title), su procedencia (title_source), titular normalizado (titulo_limpio), tokens y tokens_contenido.
- **Longitudes:** n_caracteres, n_tokens, n_tokens_contenido.
- **Categorías iniciales:** tipo_contenido, temas, temas_padre, actores, tipos_actor.

El contenido de servicio se conserva, marcado en `tipo_contenido`, para que cada análisis decida si lo usa. El código que genera el dataset está en el notebook `news-retrieval/notebooks/`

Tabla 7: Representaciones comparadas (916 452 noticias).

Técnica	Dim.	Densidad	Interpretable
BoW	44 204	0,0168 %	sí
TF-IDF (1-2 g.)	197 921	0,0052 %	sí
LSA	100	100 %	parcial
FastText	100	100 %	por vecinos

05-entrega2-eda-representacion.ipynb y en el paquete `news_corpus.eda`, con 122 pruebas automáticas.

IV. REPRESENTACIÓN DE LOS TEXTOS

4.1. Selección y justificación

Representar un texto es asignarle un vector numérico sobre el que se pueda calcular. Cada representación decide qué información conserva. Se compararon cuatro, ligadas a necesidades distintas del proyecto (Tabla 7):

- **BoW** es la línea base interpretable. El sesgo por selección léxica [17, 18] se expresa precisamente en qué palabras se eligen.
- **TF-IDF** reduce el peso de lo genérico y destaca lo específico.
- **LSA** condensa TF-IDF en dimensiones densas que agrupan palabras relacionadas.
- **FastText**, entrenado sobre el propio corpus, captura similitud semántica y representa variantes y palabras raras.

Quedó implementada como opción una quinta representación contextual, Sentence-BERT multilingüe [19], prevista para agrupar coberturas por evento.

4.2. Bolsa de palabras y TF-IDF

Fundamento. La bolsa de palabras (BoW) representa un titular d como un vector con una dimensión por palabra del vocabulario; el valor es la frecuencia $tf(t, d)$ de la palabra t en el titular. Ignora el orden, pero conserva qué

palabras se eligieron, que es la materia prima del sesgo léxico. Se incluyeron las palabras que aparecen en al menos cinco titulares.

TF-IDF [20, 21] pondera cada palabra por su especificidad: una palabra que aparece en todos los titulares (*colombia*) no distingue a ninguno, y una que aparece en pocos (*gripen*) caracteriza a los que la contienen. Se usó la variante de `scikit-learn` con frecuencia sublineal e IDF suavizado:

$$w_{t,d} = (1 + \ln \text{tf}(t, d)) \cdot \left(\ln \frac{1+N}{1+\text{df}(t)} + 1 \right), \quad (3)$$

donde N es el número de titulares y $\text{df}(t)$ el número de titulares que contienen t . Cada vector se normaliza a norma euclidiana 1. Se incluyeron unigramas y bigramas, con $\text{df} \geq 5$, y se excluyeron los términos presentes en más de la mitad de los titulares. Con vectores normalizados, la similitud entre dos titulares es el coseno del ángulo entre ellos:

$$\cos(\mathbf{a}, \mathbf{b}) = \frac{\mathbf{a} \cdot \mathbf{b}}{\|\mathbf{a}\| \|\mathbf{b}\|}, \quad (4)$$

que va de 0 (sin palabras en común) a 1 (mismo contenido), porque los pesos TF-IDF no son negativos.

Escasez. Los titulares son muy cortos (6,5–7,8 palabras de contenido de media), así que las matrices quedan casi vacías. Un titular activa en promedio unas siete de las 44 204 dimensiones de BoW. Dos titulares que tratan lo mismo con palabras distintas tienen similitud cero. Esta es la razón para complementar BoW y TF-IDF con representaciones densas.

4.3. Ejemplo de transformación

El titular de Cambio «Las razones por las que pidieron a Suecia investigar la compra de los aviones Gripen por parte de Colombia» se transforma así:

- **Tokens de contenido:** *colombia, parte, suecia, razones, investigar, aviones, compra, pidieron, gripen*.
- **BoW:** un 1 en cada una de esas nueve dimensiones.
- **TF-IDF:** los pesos mayores son para los bigramas específicos: *investigar compra* (0,402), *parte colombia* (0,353), *aviones gripen* (0,314), *compra aviones* (0,313), *gripen* (0,299).
- **FastText:** un vector denso de 100 dimensiones, el promedio de los vectores de sus palabras menos el vector medio del corpus [22], que comienza en (0,122; 0,090; −0,042; −0,054; ...).

4.4. Recuperación del mismo hecho en distintos medios

La similitud del coseno entre vectores TF-IDF, restringida a otros medios y a una ventana de ± 2 días, recupera las coberturas de un mismo hecho y reemplaza el

Tabla 8: Las seis coberturas más similares (TF-IDF) a una consulta sobre la reforma pensional, en otros medios y ± 2 días. Se restituyeron tildes y puntuación para facilitar la lectura.

Medio	Sim.	Titular (reconstruido)
RCN	0,43	Reforma pensional: Ministerio de Hacienda dio el aval fiscal al proyecto en segundo debate
Blu Radio	0,43	Reforma pensional sería completamente financiable hasta el...: Minhacienda
La República	0,38	El Minhacienda le dio el aval fiscal a la ponencia para segundo debate de la pensional
Caracol	0,26	Reforma pensional: ¿cuál sería el impacto fiscal de este proyecto?
Caracol	0,25	Minhacienda da luz verde al proyecto, pero reconoce que nuevo sistema valdrá más
Blu Radio	0,24	La reforma pensional crea una deuda impagable: Asofondos

evento_id manual de la Entrega 1. Para una consulta sobre la reforma pensional (octubre de 2023), los resultados más similares son de cuatro medios distintos y cubren el mismo hecho: el aval fiscal del Ministerio de Hacienda al proyecto (Tabla 8).

El ejemplo anticipa el objeto del proyecto. Sobre el mismo hecho, un medio destaca el aval («dio el aval fiscal»), otro la sostenibilidad («sería completamente financiable»), otro el costo («valdrá más») y otro la voz crítica de un gremio («deuda impagable: Asofondos»).

4.5. Semántica latente (LSA)

Fundamento. LSA [23] aplica una descomposición en valores singulares truncada a la matriz TF-IDF X :

$$X \approx U_k \Sigma_k V_k^T, \quad (5)$$

conservando solo las $k = 100$ direcciones de mayor varianza. Cada titular pasa a ser un vector denso de 100 componentes. Las palabras que tienden a aparecer en los mismos titulares quedan en las mismas componentes, así que dos titulares pueden parecerse sin compartir palabras. La SVD se ajustó sobre una muestra de 150 000 noticias.

Para visualizar, se usó t-SNE [24], que proyecta los vectores a dos dimensiones intentando que los vecinos cercanos sigan siéndolo. Lo hace minimizando la divergencia de Kullback-Leibler entre las afinidades de los puntos en el espacio original y en el plano. t-SNE preserva la estructura *local*, pero no las distancias entre grupos alejados ni su tamaño relativo, así que solo debe leerse como «qué se agrupa con qué».

Resultados. Las primeras componentes son interpretables:

- **2:** Estados Unidos.
- **3:** pico y placa.
- **4:** el presidente Petro.
- **5:** la selección Colombia.
- **6:** sucesos (hombre, mujer, accidente).
- **7:** dólar y petróleo.

La proyección t-SNE [24] de 3000 noticias (Figura 3) muestra que los titulares se agrupan por tema y se mezclan por medio. La representación captura de qué se habla y no quién lo publica, que es lo deseable para comparar cómo cuentan los medios un mismo tema. Hay una excepción visible: un grupo aislado de «medio ambiente» compuesto solo por titulares de RCN. Coincide con una proporción atípica del subtema «cambio climático» en ese medio (3,4 % de sus noticias), que parece responder a un formato propio y debe verificarse.

4.6. Embeddings de palabras (FastText)

Fundamento. Los *embeddings* llevan la hipótesis distribucional a un vector denso por palabra. El modelo *skip-gram* [25] aprende los vectores entrenando una tarea auxiliar: predecir las palabras que rodean a cada palabra dentro de una ventana. Usa muestreo negativo, es decir, distingue los contextos reales de palabras tomadas al azar. Las palabras que comparten contextos terminan con vectores cercanos.

FastText [26] añade información morfológica: el vector de una palabra es la suma de los vectores de sus n-gramas de caracteres, de 3 a 6. Por ejemplo, *reforma* incluye <re, ref, efo... Esto permite representar palabras no vistas en el entrenamiento y comparte información entre variantes (*reforma*, *reformas*, *contrarreforma*), algo útil porque los titulares reconstruidos desde la URL pierden tildes y pueden truncarse.

Se entrenó sobre las noticias del propio corpus para capturar el vocabulario colombiano del período, con estos parámetros:

- 100 dimensiones y ventana de 5.
- Cinco negativos por ejemplo.
- Frecuencia mínima de 5.
- Cinco épocas.

Un titular se representa como el promedio de los vectores de sus palabras de contenido, menos el vector medio del corpus. Esta corrección, una variante simple de Aro et al. [22], elimina la componente común que hace que todos los promedios se parezcan.

Resultados. Los vecinos más cercanos reflejan relaciones semánticas del período (Tabla 9). Las subpalabras también introducen vecinos por forma («salud» → «talud», «petro» → «petrovideos»), la contracara de la misma propiedad que permite manejar variantes.

Tabla 9: Vecinos más cercanos en FastText (coseno).

Palabra	Vecinos
eln	disidencias (0,79), farc (0,75), guerrilla (0,74), arauca (0,74)
paz	diálogos (0,70), total (0,69), otty (0,68), timochenko (0,65)
inflación	desinflación (0,92), estanflación (0,91), deflación (0,86)
corrupción	anticorrupción (0,88), corruptos (0,78), escándalo (0,76)
salud	secsalud (0,83), minsalud (0,72), eps (0,69)
uribe	turbay (0,86), miguel (0,84), álvaro (0,80), uribista (0,68)

4.7. Representaciones contextuales

Fundamento. En FastText cada palabra tiene un único vector, independiente de la oración: *paro* recibe el mismo vector en «paro camionero» y en «paro cardíaco». Los modelos contextuales basados en *transformers* producen un vector distinto según el contexto. Sentence-BERT [19] ajusta uno de esos modelos con una arquitectura siamesa para que oraciones con significado parecido queden cercanas bajo el coseno. Así puede reconocer paráfrasis sin palabras en común («Minhacienda da luz verde» y «Hacienda avaló el proyecto»), justo el caso que TF-IDF no resuelve. Su costo es computacional (un modelo de 470 MB y codificación lenta en CPU), por lo que quedó como opción para la fase de agrupación por eventos.

4.8. Elección para las siguientes fases

TF-IDF se mantiene como representación principal para los análisis léxicos y la recuperación del mismo hecho, por ser interpretable y eficaz con titulares cortos. FastText aporta la semántica del vocabulario y la robustez frente a variantes. Las representaciones contextuales se reservan para agrupar coberturas por evento, donde la paráfrasis entre medios es la norma.

V. LIMITACIONES Y PENDIENTES

- **Titulares reconstruidos.** Los titulares vienen de la URL. Algunos conservan códigos del *slug* (rg10) y otros pueden diferir del publicado. Su fidelidad debe reportarse con **validar-titulares**.
- **Contenido de servicio.** Formatos como «pico y placa» y «precio del dólar» aún no se clasifican como servicio.
- **Anomalía de RCN.** Hay que verificar a qué se debe la proporción de «cambio climático» en RCN.
- **Recursos léxicos.** El tesauro y la ontología requieren una validación con una muestra anotada a mano.




Figura 3: Proyección t-SNE de la representación LSA de 3 000 noticias, coloreada por tema (izquierda) y por medio (derecha).

Referencias

- [1] C. D. Manning, P. Raghavan, and H. Schütze, *Introduction to Information Retrieval*. Cambridge University Press, 2008.
- [2] G. K. Zipf, *Human Behavior and the Principle of Least Effort*. Addison-Wesley, 1949.
- [3] International Organization for Standardization, “ISO 25964-1:2011. information and documentation — thesauri and interoperability with other vocabularies — part 1: Thesauri for information retrieval,” 2011.
- [4] A. Miles and S. Bechhofer, “SKOS simple knowledge organization system reference.” W3C Recommendation, 2009.
- [5] T. R. Gruber, “A translation approach to portable ontology specifications,” *Knowledge Acquisition*, vol. 5, no. 2, pp. 199–220, 1993.
- [6] N. F. Noy and D. L. McGuinness, “Ontology development 101: A guide to creating your first ontology,” Tech. Rep. KSL-01-05, Stanford Knowledge Systems Laboratory, 2001.
- [7] J. Grimmer and B. M. Stewart, “Text as data: The promise and pitfalls of automatic content analysis methods for political texts,” *Political Analysis*, vol. 21, no. 3, pp. 267–297, 2013.
- [8] H. S. Heaps, *Information Retrieval: Computational and Theoretical Aspects*. Academic Press, 1978.
- [9] F. J. Tweedie and R. H. Baayen, “How variable may a constant be? measures of lexical richness in perspective,” *Computers and the Humanities*, vol. 32, no. 5, pp. 323–352, 1998.
- [10] P. Guiraud, *Les caractères statistiques du vocabulaire*. Presses Universitaires de France, 1954.
- [11] M. A. Covington and J. D. McFall, “Cutting the Gordian knot: The moving-average type–token ratio (MATTR),” *Journal of Quantitative Linguistics*, vol. 17, no. 2, pp. 94–100, 2010.
- [12] P. M. McCarthy and S. Jarvis, “MTLD, vocd-D, and HD-D: A validation study of sophisticated approaches to lexical diversity assessment,” *Behavior Research Methods*, vol. 42, no. 2, pp. 381–392, 2010.
- [13] G. U. Yule, *The Statistical Study of Literary Vocabulary*. Cambridge University Press, 1944.
- [14] K. W. Church and P. Hanks, “Word association norms, mutual information, and lexicography,” *Computational Linguistics*, vol. 16, no. 1, pp. 22–29, 1990.
- [15] Z. S. Harris, “Distributional structure,” *Word*, vol. 10, no. 2–3, pp. 146–162, 1954.
- [16] J. R. Firth, “A synopsis of linguistic theory, 1930–1955,” in *Studies in Linguistic Analysis*, pp. 1–32, Blackwell, 1957.
- [17] F. Hamborg, K. Donnay, and B. Gipp, “Automated identification of media bias in news articles: An interdisciplinary literature review,” *International Journal on Digital Libraries*, vol. 20, no. 4, pp. 391–415, 2019.
- [18] F. Hamborg, “Media bias, the social sciences, and NLP: Automating frame analyses to identify bias by word choice and labeling,” in *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics: Student Research Workshop*, Association for Computational Linguistics, 2020.

- [19] N. Reimers and I. Gurevych, “Sentence-BERT: Sentence embeddings using Siamese BERT-networks,” in *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing (EMNLP-IJCNLP)*, pp. 3982–3992, 2019.
- [20] K. Spärck Jones, “A statistical interpretation of term specificity and its application in retrieval,” *Journal of Documentation*, vol. 28, no. 1, pp. 11–21, 1972.
- [21] G. Salton and C. Buckley, “Term-weighting approaches in automatic text retrieval,” *Information Processing & Management*, vol. 24, no. 5, pp. 513–523, 1988.
- [22] S. Arora, Y. Liang, and T. Ma, “A simple but tough-to-beat baseline for sentence embeddings,” in *International Conference on Learning Representations (ICLR)*, 2017.
- [23] S. Deerwester, S. T. Dumais, G. W. Furnas, T. K. Landauer, and R. Harshman, “Indexing by latent semantic analysis,” *Journal of the American Society for Information Science*, vol. 41, no. 6, pp. 391–407, 1990.
- [24] L. van der Maaten and G. Hinton, “Visualizing data using t-SNE,” *Journal of Machine Learning Research*, vol. 9, pp. 2579–2605, 2008.
- [25] T. Mikolov, I. Sutskever, K. Chen, G. Corrado, and J. Dean, “Distributed representations of words and phrases and their compositionality,” in *Advances in Neural Information Processing Systems 26 (NIPS)*, pp. 3111–3119, 2013.
- [26] P. Bojanowski, E. Grave, A. Joulin, and T. Mikolov, “Enriching word vectors with subword information,” *Transactions of the Association for Computational Linguistics*, vol. 5, pp. 135–146, 2017.