

Entrega 2: textometria y topicos del corpus Duque

Evidencia exploratoria para analizar framing

Abel Albuez Sanchez, Kelly Joane Leon Torres,
Juan Camilo Torres Pena, Jesus David Romero Melo
Maestria en Ingenieria de Sistemas y Computacion, Pontificia Universidad Javeriana

Octubre de 2026

Resumen

El export contiene 708,768 registros de 6 medios entre 2018-08-07 y 2022-08-06. Hay 707,553 titulos slug y 1,215 ausentes. Se entrenaron $K=[3, 5, 7, 10, 15]$ sobre 706,083 documentos utiles, con 10 pasadas y semilla 42. $K=5$ obtuvo el mayor c_v (0.3595) de la grilla. Los resultados son descriptivos de titulos reconstruidos, no estimaciones validadas de sesgo editorial.

1. Objetivo y datos

El framing no se reduce a sentimiento ni frecuencia de palabras: requiere comprobar seleccion, enfasis y contexto del mismo acontecimiento [1]. La entrega estudia candidatos lexicos y tematicos del corpus Duque. Los ocho medios corresponden al inventario unificado, no al corte Duque: aqui hay seis, con cinco series principales y Cambio como muestra tardia.

Medio	Articulos	Titulos
blu_radio	166593	165916
cambio	98	98
el_tiempo	263145	262968
la_republica	91801	91743
noticias_caracol	109384	109085
noticias_rcn	77747	77743

El corte de fechas es inclusivo 2018-08-07 a 2022-08-06; no filtra automaticamente precision o asignacion presidencial. No hay cuerpos HTML.

2. Metodo textometrico

Se normalizan minusculas y tildes en texto y stopwords; se conservan nombres geograficos y actores. Los n-gramas son secuencias despues de filtrar stopwords y nunca atraviesan documentos. El ajuste rango-frecuencia es descriptivo [2]; correlacion alta no demuestra ley de potencia. TTR depende del tamano; MSTTR agrega ventanas completas de 50 tokens. Yule K se calcula como

$10^4 \sum_w f_w(f_w - 1)/N^2$ [3]. Vocabulario: 98418; tokens: 4737325. Pendiente ajustada: -1.035; R2: 0.969.

3. Temas y acontecimientos candidatos

Se buscan Reforma tributaria, Conflicto armado y Corrupcion mediante keywords normalizadas y limites de palabra. Se comparan proporciones sobre titulos disponibles, no conteos como sinonimo de sesgo. Las cohortes pueden solaparse. Se revisan ademas ventanas de reforma/paro 2021, bombardeo/menores 2019 y Centros Poblados 2021. Estos casos y sus ejemplos con URLs son candidatos para comprobacion humana; una coincidencia lexica no certifica el mismo hecho. Los contrastes log-odds son descriptivos y no tienen interpretacion causal. La Republica tiene 1.08% de coincidencias tributarias respecto a sus titulos; RCN y Blu registran 1.97% y 1.97% en el tema amplio de conflicto. Son proporciones de keywords, no medidas validadas de framing.

Medio	Tributaria	Conflicto	Corrupcion
blu_radio	0.42	1.97	0.67
cambio	0.00	0.00	0.00
el_tiempo	0.41	1.33	0.44
la_republica	1.08	0.10	0.35
noticias_caracol	0.32	1.66	0.51
noticias_rcn	0.37	1.97	0.53

Las columnas anteriores son porcentajes de titulos del medio. Cambio (98 titulos) no tiene el mismo alcance temporal; cero coincidencias no prueba ausencia de cobertura. El bigrama mas frecuente es 'programa completo' (8,822 apariciones). Programacion de radio y emisiones condicionan los resultados; no confundir formato con posicion editorial.

4. Modelado de topicos

Se usa LDA [4] sobre todos los documentos con vocabulario util, sin muestreo. Diccionario: frecuencia documental minima 10, maxima .7 y hasta 10000 terminos. Se




Figura 1: Rango-frecuencia: ajuste descriptivo, no certificación de ley de potencia.




Figura 2: Diversidad lexica por medio con indicadores sensibles a longitud.

entrenan $K=3,5,7,10,15$, diez pasadas, 50 iteraciones internas y semilla 42. Se elige el mayor c_v de entrenamiento, no un optimo universal. La perplejidad aproximada se transforma desde log-bound en base 2. Documentos sin vocabulario reciben -1, no un topico inventado. El mejor K de la grilla fue 5 con $c_v=0.3595$; documentos utiles: 706083.

- Topico 0: emision, bogota, martes, jueves, nacional, miercoles, lunes, colombia
- Topico 1: covid, colombia, dos, bogota, anos, tras, coronavirus, personas
- Topico 2: colombia, duque, ucrania, unidos, presidente, rusia, gobierno, viernes
- Topico 3: colombia, asi, video, tras, pico, primera, america, mundial
- Topico 4: petro, gustavo, luis, caso, diaz, covid, nuevos, fiscalia

5. Limitaciones y conclusiones

- Todos los titulos disponibles son proxies slug; no titulares editoriales verificados.

- No hay cuerpos HTML: no se pueden estudiar citas, actores en contexto o framing textual completo.
- Cinco medios principales y Cambio con 98 articulos: no ocho medios comparables.
- Las fechas month y lastmod requieren cautela; un corte por fecha no certifica gobierno.
- Keywords seleccionan temas/candidatos, no eventos verificados ni omisiones demostradas.
- LDA/coherencia se evaluan en entrenamiento; el mejor K no es un optimo universal.
- Programas, emisiones y audio forman parte del archivo; la mezcla de formatos puede dominar las frecuencias.

No se concluye que un medio sea mas parcializado. Se obtienen proxies lexicos y de agenda que orientan una submuestra balanceada para recuperar titulares reales/cuerpos, verificar pares de acontecimientos y anotar framing. La comparabilidad requiere controlar fuente de titulo, precision temporal, cobertura de archivo y longitud.




Figura 3: N-gramas frecuentes del texto depurado.




Figura 4: Cobertura relativa de temas por medio; no es una medicion de framing.

6. Reproducibilidad

El notebook integrado carga resultados medidos. Se conservan modelos por K, diccionario, corpus, asignaciones por article_id, versiones, parametros y SHA-256 del Parquet. No se modifican las bases PostgreSQL ni el export de entrada. Los resultados no sustituyen la validacion manual.

Referencias

- [1] R. Entman. Framing: Toward Clarification of a Fractured Paradigm. *Journal of Communication*, 43(4), 51–58, 1993.
- [2] G. Zipf. *Human Behavior and the Principle of Least Effort*. Addison-Wesley, 1949.
- [3] G. Yule. *The Statistical Study of Literary Vocabulary*. Cambridge University Press, 1944.

- [4] D. Blei, A. Ng y M. Jordan. Latent Dirichlet Allocation. *Journal of Machine Learning Research*, 3, 993–1022, 2003.




Figura 5: Comparacion de K: coherencia y perplejidad de entrenamiento.




Figura 6: Topico dominante: conteos condicionados por el volumen del archivo.




Figura 7: Proporciones de temas por medio.