Detección de sesgo mediático en cinco medios colombianos bajo los gobiernos Duque y Petro

Abel Albuez Sanchez, Kelly Joane Leon Torres,
Juan Camilo Torres Peña, Jesús David Romero Melo
Maestría en Ingeniería de Sistemas y Computación, Pontificia Universidad Javeriana, Bogotá D.C., Colombia
Procesamiento de Lenguaje Natural, 2026 — Entrega 3 (final)

Resumen

Estudiamos si cambió la cobertura de El Tiempo, Blu Radio, Noticias RCN, Noticias Caracol y La República entre los gobiernos de Iván Duque y Gustavo Petro, con 1.573.421 titulares reconstruidos desde la URL. A diferencia de la Entrega 2, que analizó cada gobierno por separado, esta entrega usa un solo corpus y un solo modelo para los dos gobiernos, y pasa de comparar agendas a comparar el mismo hecho entre medios. El modelo final tiene tres componentes: BERTopic para la agenda, elegido frente a tres variantes de LDA por ser el único estable entre semillas (19 de 20 tópicos, Jaccard 0,79); un emparejamiento de titulares del mismo hecho con embeddings multilingües, cuyo umbral se calibró con 210 parejas anotadas a mano (precisión 81 %, $\kappa = 0{,}77$); y medidas de encuadre validadas con un silver standard de 300 titulares. Las diferencias entre medios son pequeñas y sobre todo de perfil y estilo. Lo que cambia con Petro es común a todos: más asuntos públicos, más «Gobierno Petro» y más carga negativa. Ningún medio trata de forma robusta más desfavorablemente a un gobierno que al otro, y la carga léxica no equivale a sesgo juzgado ($F1 \leq 0{,}22$; AUC del clasificador 0,56–0,62).

Index Terms— media bias, framing, topic modeling, BERTopic, event matching, silver standard, Spanish NLP, Colombian news.

I. INTRODUCCIÓN

El sesgo mediático no se reduce al tono. Se expresa en qué temas cubre un medio (agenda), qué hechos cubre y cuáles no (selección) y con qué palabras los cuenta (encuadre) [1, 2]. Por eso el proyecto descarta el análisis de sentimiento como medida de sesgo: un atentado se cuenta en negativo en todos los medios, y eso no dice nada de su línea editorial. El foco, como en [3], está en la elección de palabras y en cómo se nombra a los actores.

Pregunta. ¿Cambió la forma en que los cinco medios cubren la actualidad entre Duque (2018-08 a 2022-08) y Petro (2022-08 a 2026-08)? ¿Algún medio cambió más que los otros y, en particular, trata con más dureza a uno de los dos gobiernos? La pregunta se responde en tres niveles, de lo más fácil a lo más difícil de medir:

Nivel	Pregunta	Método
Agenda	¿De qué habla cada medio?	Modelos de tópicos; Δ relativo
Selección	¿Quién cubre el mismo hecho?	Eventos entre medios; omisión
Encuadre	¿Con qué palabras?	Log-odds, personalización, carga, silver standard

Todo el análisis es descriptivo. Una palabra cargada o un tema distinto no son, por sí solos, sesgo, y ninguna medida dice *por qué* cambió un medio.

II. CORRECCIONES RESPECTO A LA ENTREGA 2

La Entrega 2 tuvo dos partes, una por gobierno: (a) textometría, keywords temáticas y LDA sobre el corpus de Duque (708.768 registros), y (b) EDA avanzado, tesauro, ontología de actores y representaciones (BoW, TF-IDF, LSA, FastText) sobre el corpus de Petro (984.590 titulares). La retroalimentación del profesor fue construir un *silver standard* de titulares sesgados. La Tabla 1 resume qué se cambió y por qué. Cada razón sale de un resultado medido en la Entrega 2 o en esta.

III. DATOS

El corpus `news_corpus` (dump 2026-10-04) contiene las URLs de los sitemaps de cada medio. Descargar el cuerpo sólo fue posible para cerca del 1 % de las URLs, así que la unidad de análisis es el titular reconstruido desde el slug (sin tildes, cifras ni puntuación).

Paso	Titulares
Export 2018-08 a 2026-08 (todos los medios)	1.716.219
Gobierno Duque o Petro	1.698.581
5 medios con los dos gobiernos	1.653.170
Noticias (sin `non_news_reason`)	**1.573.421**
Subcorpus de asuntos públicos	313.170

Tres cuidados valen para todo el informe. (1) El volumen depende de cómo cada medio arma sus sitemaps, por lo que se comparan proporciones dentro de cada medio

Tabla 1: Correcciones y mejoras respecto a la Entrega 2, con la razón que las motivó.

Aspecto	Entrega 2	Entrega 3	Razón (resultado que la motiva)
Corpus	Dos corpus separados, uno por gobierno; Cambio con 98 titulares en Duque.	Un corpus con los cinco medios presentes en los dos gobiernos: 1.573.421 noticias.	Comparar gobiernos exige la misma unidad y los mismos medios; Cambio sólo cubre a Petro.
Titular y limpieza	Slug con el código del CMS (`rg10`); formatos de servicio sin marcar.	Se quita el código en 322.705 URLs; se marcan 78.859 piezas no informativas (precisión 96 % en 100 revisadas).	`rg10` era la palabra más frecuente de Blu Radio y Caracol, y «programa completo» el bigrama más frecuente de Duque (8.822).
Preparación para tópicos	LDA sobre todos los titulares de Duque, stopwords genéricas; K=5 por c_v de entrenamiento (0,360).	Muestra balanceada por medio × gobierno; stopwords de dominio (días, meses, formato); bigramas; perplejidad en held-out.	Un tópico de la Entrega 2 era «emisión, Bogotá, martes, jueves»; El Tiempo es el 42 % de las noticias y, sin balancear, el volumen define los tópicos.
Selección del modelo de tópicos	Una semilla; sólo c_v.	Estabilidad con tres semillas; LDA, priors dispersos, LDA de consenso y BERTopic.	10 de los 15 tópicos del LDA cambiaban con la semilla: el mayor c_v no garantizaba tópicos reproducibles.
Medida de cambio	Proporción del tópico dominante por medio.	Δ relativo con la distribución θ completa; bootstrap de bloques (20.000 réplicas), Holm y control por sección.	La agenda de todos cambia (COVID); la sección deportes de RCN pasa de ∼1 % a 43–45 % de sus URLs; con 2.000 réplicas y 125 pruebas, el mínimo p ajustado por Holm era 0,0625 y ningún cambio podía ser significativo.
Mismo hecho	Duque: ventanas de keywords sin verificar. Petro: coseno TF-IDF en ±2 días, un ejemplo, sin precisión medida.	Embeddings Sentence-BERT (previstos en la Entrega 2), parejas recíprocas y partición de componentes; umbral calibrado a mano.	TF-IDF no reconoce paráfrasis («Minhacienda da luz verde» frente a «Hacienda avaló»); un umbral sin precisión medida no es defendible.
Encuadre	Log-odds y n-gramas entre medios, sobre todo el corpus.	Log-odds emparejado por evento, personalización, léxico de carga validado, banda 0,65–0,80.	Comparar medios fuera del mismo hecho mezcla agenda y encuadre.
Validación	Pendiente: «faltan anotación humana y texto publicado».	Silver standard de 300 titulares, a ciegas del medio y ponderado.	Retroalimentación del profesor; medir si los indicadores automáticos se parecen al juicio humano.
Subcorpus	El tesauro (Entrega 2, Petro) sólo describía el corpus.	Subcorpus de asuntos públicos: 313.170 titulares con una etiqueta del tesauro en el titular.	Fútbol, farándula y sucesos dominaban la agenda del corpus completo.

y nunca conteos. (2) RCN tiene fecha exacta sólo desde 2020-09, así que las comparaciones por eventos usan Duque desde esa fecha. (3) El archivo de RCN cambia de composición (deportes pasa de ∼1 % a 43–45 % de sus URLs), lo que motiva el control por sección.

IV. DESARROLLO DEL MODELO FINAL

4.1. Componentes

El modelo final es un pipeline con tres componentes entrenados o calibrados sobre el corpus, más un clasificador de prueba de concepto (Tabla 2).

Tabla 2: Componentes del modelo final.

Componente	Tipo	Evaluación
Agenda: BERTopic	Modelado de tópicos (embeddings + clustering)	c_v, estabilidad entre semillas, correlación del Δ
Mismo hecho: eventos	Clustering con umbral sobre embeddings	Precisión anotada a mano, κ de Cohen
Encuadre: léxico de carga	Clasificador de diccionario	Precisión, recall y F1 frente al silver standard
Sesgo del titular	TF-IDF + regresión logística (prueba de concepto)	AUC-ROC y AP, validación cruzada

4.2. Agenda: entrenamiento, evaluación y selección

Preparación. Los titulares se tokenizan con stopwords de dominio y se detectan bigramas (`gustavo_petro`, `reforma_pensional`). Los modelos se ajustan con una muestra balanceada para que ningún medio defina los tópicos por volumen: 40.000 titulares por medio × gobierno en el corpus completo y 14.000 en el subcorpus. Luego se aplican a todos los titulares.

LDA [4]. Se probó una grilla de K = 10–40 en el corpus completo y de K = 10–30 en el subcorpus. Para cada K se

Tabla 3: Evaluación de los modelos de tópicos. Δ fiable: Holm < 0,05, tópico no inestable y mismo signo con las otras dos semillas.

Modelo	K	c_v	Jacc.	Robustos	Corr. Δ	Δ fiables
LDA completo	15	0,417	0,25	3/15	0,88	13 / 5
LDA público	25	0,360	0,19	1/25	0,67	7 / 2
LDA consenso	12	0,319	0,22	0/12	0,76	2 / 1
BERTopic	20	0,398	**0,79**	**19/20**	**0,95**	**22 / 10**

Δ fiables: sin / con control por sección, sobre 75, 125, 60 y 100 pares medio × tópico.

midió la coherencia c_v [5] y la perplejidad en un conjunto held-out. La perplejidad crece con K en las dos grillas (de 1.131 a 2.418 en el corpus completo), así que no ayuda a elegir. El máximo c_v está en K = 15 en el corpus completo (0,417) y en K = 25 en el subcorpus (0,360).

Estabilidad. Cada modelo se reentrenó con las semillas 7 y 123. Los tópicos se emparejaron con el algoritmo húngaro y se compararon por sus 10 palabras principales con el índice de Jaccard: un tópico es robusto si el índice es ≥ 0,5 y parcial si está entre 0,3 y 0,5. También se midió si el Δ relativo (§4.3) se mantiene entre semillas. El LDA resultó inestable: sólo 3 de sus 15 tópicos son robustos. Ni los priors dispersos ($\alpha = 0{,}05$, $\eta = 0{,}01$, 20 pasadas) ni un LDA de consenso (EnsembleLda: 16 LDA de K = 25 por semilla) lo corrigieron. Los tópicos de consenso tampoco se repiten entre ensambles.

BERTopic [6]. Usa los embeddings del modelo multilingüe de Sentence-BERT [7, 8] `paraphrase-multilingual-MiniLM-L12-v2`, UMAP a 5 dimensiones [9] y k-means con k = 20. Se usa k-means en lugar de HDBSCAN para que todo titular tenga un tópico: HDBSCAN suele dejar el 30–40 % como ruido, y entonces las participaciones por medio no serían comparables. Los tópicos se describen con c-TF-IDF sobre el mismo vocabulario del LDA. El valor k = 20 se fijó dentro del rango de la grilla del LDA, sin grilla propia.

Selección. La Tabla 3 resume la evaluación. La c_v varía poco entre modelos (0,32–0,42) y no separa los buenos de los malos: el LDA del corpus completo tiene la c_v más alta, pero sólo 3 de sus 15 tópicos se repiten con otra semilla. Con ∼6 palabras útiles por titular, el LDA no tiene suficiente co-ocurrencia por documento para fijar los tópicos. BERTopic, en cambio, se apoya en embeddings preentrenados. **Se eligió BERTopic**: repite 19 de sus 20 tópicos con otras semillas, y su Δ relativo, que es lo que se interpreta, casi no cambia (r = 0,95). La c_v del corpus completo no es directamente comparable con la del subcorpus, porque se calcula con textos distintos.

4.3. Δ relativo y control por sección

El Δ **relativo** es el cambio Duque → Petro en la participación de un tópico en un medio, menos el cambio promedio de los otros cuatro. Así se descuenta lo que cambió en la agenda de todos (por ejemplo, el COVID). Los intervalos de confianza salen de un bootstrap por bloques de 3 meses [10], porque las participaciones mensuales están autocorrelacionadas, con 20.000 réplicas y corrección de Holm [11]. El **control por sección** repondera cada medio para que tenga la misma mezcla de sus propias secciones en los dos gobiernos.

Tabla 4: Precisión del emparejamiento según el umbral, ponderada por la población de cada tramo.

Umbral	Parejas en el corpus	Precisión	IC 95 %
0,70	73.498	62 %	54–69
0,75	53.945	75 %	67–83
0,80	**35.843**	**81 %**	**72–90**
0,85	20.654	84 %	74–94
0,90	9.198	93 %	82–100

4.4. Mismo hecho: emparejamiento y calibración

Este componente no se entrena: se calibra su umbral. Cada titular del subcorpus con fecha al día (304.039, tras excluir 1.256 páginas de plantilla masiva) se compara con los titulares de los otros medios en ±2 días, por el coseno de sus embeddings. Dos titulares A y B forman pareja si cada uno es el más parecido al otro en su medio y la similitud supera el umbral. Las parejas se unen en componentes conexas. Una componente que tiene dos titulares del mismo medio o dura más de 5 días se parte con enlace completo; así se partieron 1.311 de 20.408.

Evaluación. Dos personas anotaron 210 parejas, 30 por tramo de similitud, con 60 parejas dobles. El acuerdo fue $\kappa = 0{,}77$ [12] en «mismo hecho sí/no». La precisión de cada umbral se pondera por la población de parejas de cada tramo, con IC normales (Tabla 4).

Selección: umbral 0,80. El salto de precisión está entre 0,75 y 0,80. Por debajo de 0,75, una de cada cuatro parejas aceptadas no es el mismo hecho, sino casi siempre el mismo tema. El 0,90 llega al 93 %, pero conserva una cuarta parte de las parejas y pierde justo los titulares del mismo hecho redactados de forma distinta, que son los que interesan para comparar encuadres. Con 0,80 hay 20.905 eventos: 5.867 con ≥ 3 medios y 342 con los cinco. **El recall no se midió**, y por eso no se reporta F1. Como cota, entre el 27 % y el 54 % de las ausencias de los cuatro medios generalistas en un evento tenían un titular con similitud ≥ 0,75 que podría ser el mismo hecho.

4.5. Medidas de encuadre y de selección

- **Omisión.** Para cada evento que cubren al menos 3 de los otros 4 medios, se registra si el medio también lo cubre. Exigir ese mínimo en los otros medios evita que un medio defina qué es noticia.
- **Léxico.** Log-odds con prior de Dirichlet informativo [13], calculado sobre la presencia de cada palabra por

titular y emparejado por evento. Se usa bootstrap por eventos y meses, y FDR de Benjamini-Hochberg [14].

- **Personalización.** Porcentaje de titulares que dicen «Gobierno Petro» o «Gobierno Duque» entre los que dicen «gobierno».
- **Carga.** Léxico evaluativo curado: 74 entradas con polaridad y tipo. Se validó con concordancias (KWIC) sobre 49.759 titulares, y 28 entradas cambiaron tras revisar sus contextos. No es análisis de sentimiento.
- **Banda 0,65–0,80.** Se repite el análisis léxico con parejas de menor similitud. Esas parejas deben tener la misma fecha y compartir un término raro; el filtro tiene ∼72 % de precisión con validación cruzada anidada.

4.6. Silver standard y clasificadores de titular sesgado

Muestra. 300 titulares de asuntos públicos, 30 por medio × gobierno, de una población elegible de 290.464. Entre otras exclusiones, quedan fuera la opinión declarada, el fútbol y los titulares que nombran un medio. Cada celda mezcla titulares al azar (en evento o sueltos) con candidatos: titulares con léxico cargado, con personalización o divergentes de su evento. Para estimar tasas reales, cada titular pesa N_h/n_h.

Anotación. Se anota a ciegas del medio: no se muestran el medio, la URL ni la sección. Cuando el titular pertenece a un evento, se muestran como contexto hasta 4 titulares de otros medios sobre el mismo hecho. Para cada titular se pregunta si está sesgado y, si lo está, el tipo, la dirección respecto al gobierno de turno y la intensidad. Hay dos planillas de 180 titulares con 60 dobles. **La planilla 1 la anotó una persona del equipo y la 2 un modelo de lenguaje** (Claude). Por eso todo se reporta por anotador y con dos combinaciones: laxa (un desacuerdo cuenta como sesgado) y estricta (como no sesgado). Las tasas llevan IC de Wilson [15] con el n efectivo de Kish [16].

Indicadores como clasificadores. Cada indicador léxico se evalúa como una regla («marca» = sesgado) frente a cada etiqueta, con precisión, recall y F1 ponderados a la población (Tabla 5). Además se entrenó un **clasificador supervisado**: TF-IDF de palabras y de caracteres con regresión logística, evaluado con validación cruzada estratificada 5 × 10 (Tabla 6).

Interpretación. El mejor F1 es 0,18 con la etiqueta de la persona, 0,19 con la de la IA y 0,22 con la combinada laxa (Fig. 1). El léxico de carga acierta más que el azar: su precisión supera la prevalencia y concentra entre 1,3 y 1,9 veces más titulares sesgados. Pero deja fuera a ∼85 % de ellos. Los verbos de atribución cargados («arremete», «denuncia») están por debajo de la prevalencia, es decir, peor que el azar. En «Gobierno Petro/Duque», la persona juzgó sesgados 7 de 14 titulares y la IA, 1 de 13. El clasificador supervisado queda cerca del azar (AUC 0,56–0,62, frente a 0,5 del azar) y no le gana a la regla «tiene una palabra del léxico». Con 180–300 ejemplos y un acuerdo entre anotadores de $\kappa = 0{,}30$ (§5.4), la propia etiqueta limita lo que se puede aprender. Por eso el clasificador **no se usa** para estimar tasas: las tasas de sesgo salen directamente de las etiquetas, ponderadas.

Tabla 5: Indicadores léxicos como clasificadores de titular sesgado, ponderados a la población. P: precisión; R: recall (cobertura).

	Persona (prev. 0,30)			IA (prev. 0,12)		
Indicador	P	R	F1	P	R	F1
Léxico de carga (todo)	0,40	0,12	0,18	0,23	0,14	0,18
Léxico negativo	0,35	0,09	0,14	0,34	0,14	0,19
Verbos atrib. cargados	0,11	0,02	0,03	0,10	0,01	0,02
Titular divergente	0,42	0,04	0,08	0,11	0,03	0,05

Tabla 6: Clasificador TF-IDF + regresión logística (validación cruzada 5 × 10) frente a una sola marca del léxico. Prevalencia en la muestra.

Etiqueta	n	Prev.	AUC	AP	AUC léxico
Persona	176	0,47	0,62 ± 0,09	0,62	0,66
IA	180	0,17	0,56 ± 0,09	0,24	0,62
Combinada laxa	297	0,34	0,60 ± 0,06	0,47	0,65

4.7. Ejemplos de salida

La Tabla 7 muestra salidas de cada componente. En los titulares se restituyeron las tildes para facilitar la lectura.

V. ANÁLISIS DE RESULTADOS

5.1. Agenda

El control por sección se lleva la mayoría de los cambios. En el LDA del corpus completo, de 13 Δ fiables quedan 5 tras el control. Por ejemplo, Fútbol en RCN pasa de +11,5 a +5,5 pp y deja de ser significativo. Con BERTopic y control por sección sobreviven los cambios de la Tabla 8 (Fig. 2). Con Petro hay más asuntos públicos en cuatro de los cinco medios; por ejemplo, El Tiempo pasa de 15,8 a 21,8 % y Blu Radio de 19,7 a 24,4 %. Las agendas también se separan un poco: la distancia Jensen-Shannon media entre medios pasa de 0,180 a 0,204. Tres hallazgos se repiten en al menos dos modelos: El Tiempo cubre más inseguridad urbana (+1,1 a +1,7 pp) y menos justicia (−0,7 a −1,1 pp), y La República cubre más guerras y geopolítica (+1,2 a +1,6 pp).

El Δ relativo puede tener otro signo que el cambio absoluto. Por ejemplo, Policía y delitos baja en El Tiempo (7,7 → 7,2 %), pero baja mucho más en los otros medios.

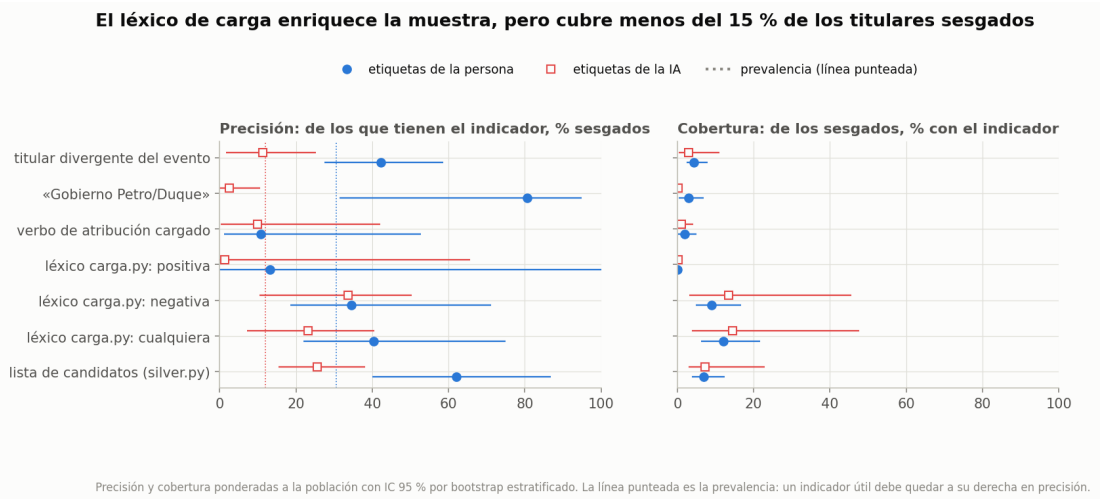


Figura 1: Precisión y cobertura (recall) de los indicadores automáticos frente a las etiquetas, ponderadas a la población, IC 95 %.

Tabla 7: Ejemplos de salida del modelo. BERTopic: palabras c-TF-IDF y el titular más cercano al centroide del tópico (coseno). Eventos: titulares de distintos medios agrupados como el mismo hecho. Silver standard: marca del léxico de carga frente a las dos etiquetas.

Componente	Entrada / rasgos	Salida
T5 Venezuela, Cuba y Maduro	venezuela, maduro, cuba, venezolanos, nicolas_maduro, machado	«Venezuela autorizó a Latam para operar entre Bogotá y Caracas» (RCN, 0,94)
T4 Policía y delitos	policia, bogota, homicidios, estacion_policia, cali, hurto	«Atentado de las disidencias de las FARC contra la Policía en Huila» (El Tiempo, 0,91)
T17 Reforma a la salud	reforma_salud, eps, ministro_salud, sistema_salud	«Claves de la reforma a la salud presentada por el Gobierno Petro» (Blu Radio, 0,93)
Evento, 2020-02-07	4 medios	«Fernando Ruiz, **cercano a Vargas Lleras**, es el nuevo ministro de Salud» frente a «Fernando Ruiz Gómez es el nuevo ministro de Salud»
Evento, 2025-03-05	4 medios; mensaje de urgencia de la reforma a la salud	«**Gobierno Petro** radicó…» (Blu Radio), «…**Gobierno Petro insiste**…» (El Tiempo), «**Armando Benedetti** radicó…» (Caracol), «**Gobierno** radicó…» (RCN)
Silver standard	«Gustavo Petro arremete contra Bukele y tacha de falso positivo cifra de homicidios en El Salvador» — léxico: *arremete*	Persona: sesgado (sensacionalismo); IA: sesgado (lenguaje cargado). Acuerdo en sesgo, no en tipo
Silver standard	«Polémica por fallo de la Corte Suprema sobre protestas» — léxico: *polémica*	Persona: sesgado (lenguaje cargado); IA: no sesgado. Umbral distinto
Silver standard	«Personería suspendió a funcionaria de la UAESP tras escándalo de corrupción» — léxico: *escándalo*	Ninguno lo juzga sesgado: falso positivo del léxico
Silver standard	«Venezuela echa por tierra el mito de la no intervención» — sin marca del léxico	Los dos lo juzgan sesgado: falso negativo del léxico

5.2. Selección

Los perfiles de cada medio son estables entre gobiernos. El más marcado es el de La República, con ∼20 pp menos en policía, justicia y conflicto y más en economía e impuestos: es el perfil de un diario económico, no una omisión. Casi nada cambia de un gobierno al otro. El único cambio robusto es RCN en Justicia: +7,5 pp frente a los otros medios (IC 2,9–12,7; Fig. 3). Caracol en Venezuela (+14,4 pp) sólo conserva el signo en las pruebas de robustez. Como el recall del emparejamiento no está medido, la omisión es una cota superior.

5.3. Encuadre

Las palabras distintivas de cada medio son sobre todo de estilo de casa: El Tiempo usa nombres completos («Donald Trump» en el 75 % de sus titulares sobre Trump) y Blu Radio formas cortas. El hallazgo más claro es de periodo: **todos los medios personalizan más al gobierno con Petro** (Fig. 4). El Tiempo pasa de 5,1 a 26,9 %, Caracol de 7,6 a 28,4 %, Blu Radio de 5,4 a 17,0 % y RCN

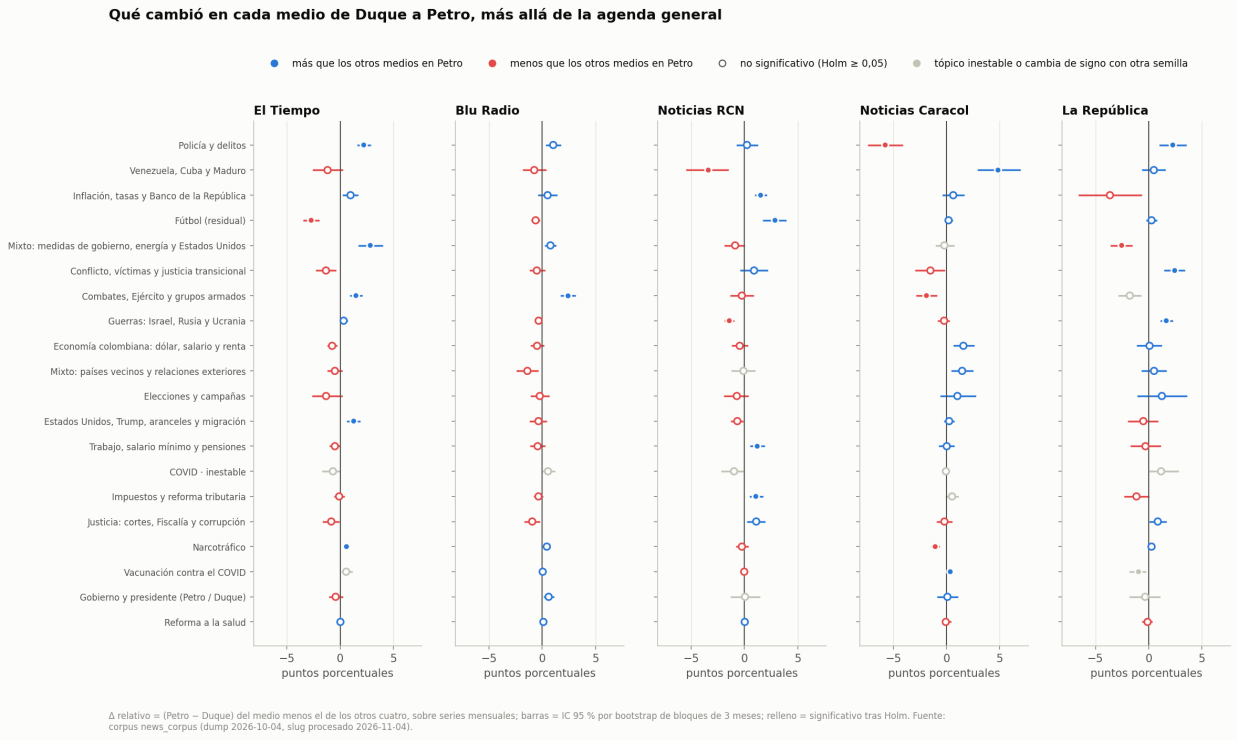


Figura 2: Δ relativo por medio y tópico (BERTopic, asuntos públicos, con IC 95 %).

Tabla 8: Δ relativo significativo con BERTopic y control por sección. Duque y Petro: participación del tópico en el medio (%); Δ relativo en pp. Se omiten el tópico mixto 8, que no es un tema, y Vacunación (+0,4 pp).

Medio	Tópico	Duque	Petro	Δ rel. (IC 95 %)
Caracol	Venezuela y Maduro	6,6	10,0	+3,8 (2,1; 5,6)
Caracol	Policía y delitos	17,1	10,5	−2,8 (−4,4; −1,2)
El Tiempo	Policía y delitos	7,7	7,2	+1,7 (1,0; 2,4)
El Tiempo	Conflicto y víctimas	12,8	9,3	−1,6 (−2,5; −0,7)
La Rep.	Guerras	1,8	3,7	+1,6 (1,0; 2,2)
Caracol	Narcotráfico	2,7	1,7	−0,9 (−1,3; −0,5)
El Tiempo	Narcotráfico	2,6	2,9	+0,5 (0,3; 0,8)

de 3,9 a 12,1 %; en La República el cambio no es significativo. Hay 191 eventos de Petro en los que un medio escribe «Gobierno Petro» y otro sólo «Gobierno», frente a 9 de Duque. Ante los mismos hechos con Petro, El Tiempo personaliza +11,2 pp más que los otros medios, y RCN (−12,7), La República (−7,9) y Blu Radio (−5,1) menos. Con Duque ningún medio se distingue.

En carga, las diferencias entre medios ante el mismo hecho son de 3 pp como mucho. Caracol usa más carga negativa con Duque (+2,4 pp) y La República menos con Petro (−3,1 pp). Blu Radio usa unos +12 pp más de verbos de atribución cargados, en los dos gobiernos. En los titulares sobre el gobierno ningún medio carga más que los otros, y la carga negativa sube en conjunto de 5,2 % a 9,7 % con Petro (Fig. 5). En la banda 0,65–0,80 no aparece encuadre nuevo, y la personalización se mantiene (El Tiempo +15,2 pp).

5.4. Silver standard

El acuerdo entre la persona y la IA es bajo, pero tiene una estructura clara: $\kappa = 0{,}30$ en «sesgado sí/no» y ≈ 0 en tipo y dirección. En los 60 dobles, la persona marcó 32 titulares sesgados y la IA 10, y los 10 de la IA están entre los 32 de la persona. Es un umbral distinto, no ruido: la IA aplica la guía al pie de la letra y no cuenta como sesgo una opinión atribuida a su fuente.

Las tasas ponderadas son de 39 % con Duque y 21 % con Petro según la persona, y de 14 % y 12 % según la IA. **El sesgo juzgado no sube con Petro**, aunque la carga sí sube. Ninguna diferencia Petro − Duque por medio es significativa (Fig. 6): con unos 18 titulares por celda y anotador, los IC son de ±30–50 pp. Según la IA, Caracol es el medio con más titulares sesgados (41 %, IC 21–64). En La República hay un indicio de menos sesgo desfavorable al gobierno con Petro (−25 pp, $p = 0{,}05$ sin corrección múltiple). La validación de los indicadores automáticos está en §4.6.

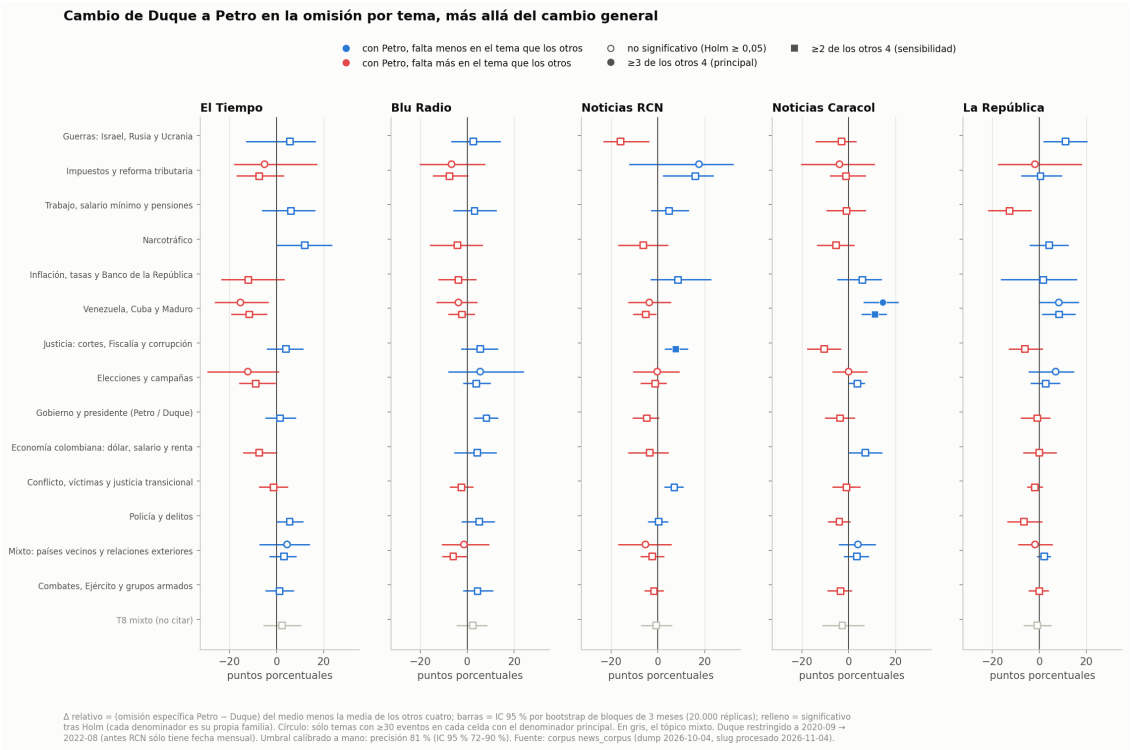


Figura 3: Cambio de Duque a Petro en la omisión por tema (Δ relativo frente a los otros medios, IC 95 %).

5.5. ¿Coinciden los análisis?

Análisis previo	Silver standard
Carga negativa sube con Petro	El sesgo juzgado no sube: carga ≠ sesgo
Personalización sube	Casi nunca se juzga sesgo: es estilo o periodo
Blu Radio: verbos cargados	Precisión ∼10 %: estilo de casa
Caracol: más carga con Duque	Tasa más alta según la IA: consistente, débil
La República: menos carga con Petro	Menos sesgo desfavorable: indicio

VI. DISCUSIÓN

6.1. Patrones e implicaciones

1. Lo común pesa más que lo propio. Los cambios más grandes entre Duque y Petro aparecen en los cinco medios a la vez: más asuntos públicos, más «Gobierno Petro» y más carga negativa sobre el gobierno. Si cada medio se comparara sólo consigo mismo, estos cambios se leerían como decisiones editoriales de cada uno. El Δ relativo y el diseño emparejado por evento son lo que permite separar el cambio del periodo del cambio de un medio. Que el gobierno de Petro se nombre como «Gobierno Petro» en todos los medios encaja mejor con un cambio de periodo, en el estilo del gobierno o en su agenda, que con una postura de un medio. Este análisis, sin embargo, no puede probar la causa.

2. El archivo imita decisiones editoriales. El control por sección quita 8 de los 13 cambios del LDA, entre ellos el más llamativo, Fútbol en RCN. Eran cambios en cuánto pesa cada sección en el sitemap, no en qué cubre el medio. La implicación vale para cualquier estudio sobre archivos web: antes de hablar de agenda hay que controlar la composición del archivo.

3. Carga no es sesgo. Las palabras cargadas aumentan con Petro y el sesgo juzgado no. El léxico tiene F1 $\leq$ 0,22 y no ve el 85 % de los titulares sesgados. Un monitor de sesgo basado en léxicos, o en sentimiento, mediría otra cosa: sirve para elegir candidatos a revisión (los concentra 1,3–1,9 veces), no para estimar tasas. Es la advertencia de [17]: un método de diccionario debe validarse sobre el corpus antes de interpretarse.

4. El juicio de sesgo depende de quién anota. Con $\kappa = 0{,}30$, la frontera entre sesgo y no sesgo a nivel de titular depende del umbral de quien anota. El modelo de lenguaje aplicó la guía de forma más literal y conservadora: sus «Sí» son un subconjunto de los de la persona. Sirve como segundo anotador o como filtro, pero no reemplaza el juicio humano. Cualquier tasa de sesgo de un medio debería reportarse junto con quién anotó y con qué guía.

5. Textos cortos: embeddings antes que LDA. Con titulares de ∼6 palabras útiles, el LDA no da tópicos reproducibles ni con consenso, mientras que BERTopic repite 19 de 20. Para titulares en español, la estabilidad entre semillas discrimina mejor entre modelos que la coherencia c_v.

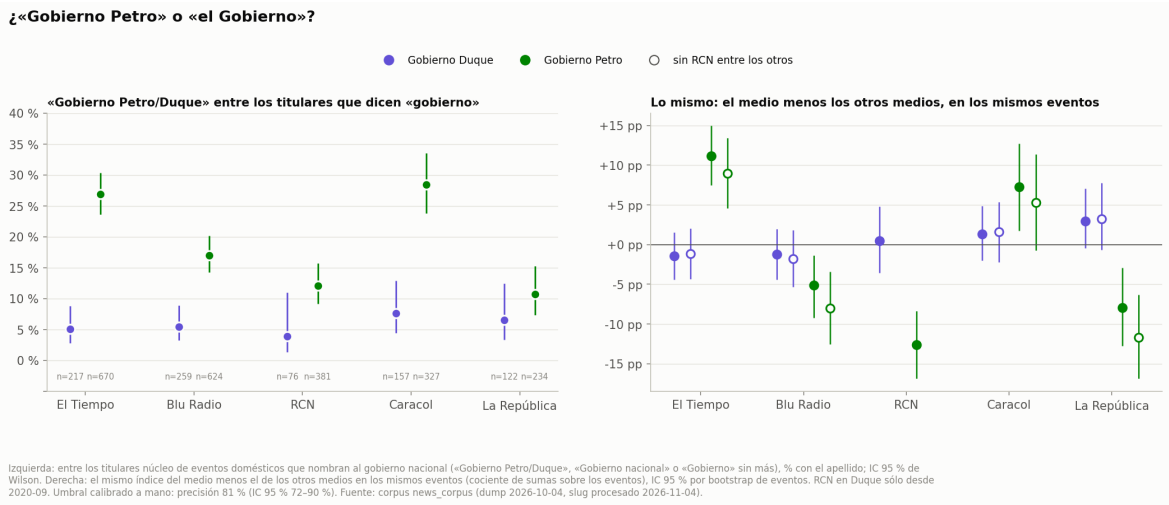


Figura 4: «Gobierno Petro/Duque» entre los titulares que dicen «gobierno», por medio y gobierno (izquierda), y frente a los otros medios en los mismos eventos (derecha).

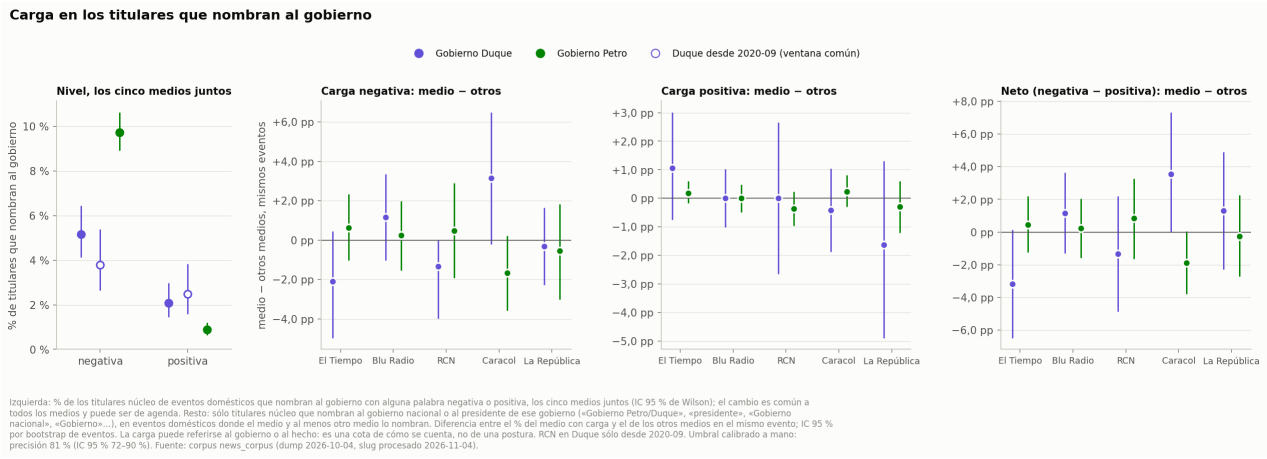


Figura 5: Carga en los titulares que mencionan al gobierno: nivel en los cinco medios y diferencia de cada medio frente a los otros en los mismos eventos.

6.2. Limitaciones

- El segundo anotador del silver standard es un modelo de lenguaje: el κ mide el acuerdo entre la persona y el modelo, y quedan 32 desacuerdos sin adjudicar.
- Hay $\sim$18 titulares por medio $\times$ gobierno y anotador, con un n efectivo de $\sim$10, así que los IC por medio son muy anchos.
- El tipo y la dirección del sesgo no son fiables ($\kappa \approx 0$).
- Los titulares se reconstruyen desde la URL: no tienen tildes, cifras, comillas ni signos, y por eso se pierde la atribución de las citas.
- El emparejamiento acierta en $\sim$81 % de los casos y su recall no está medido.
- En BERTopic, k = 20 no se eligió con una grilla propia. Cada titular recibe un solo tópico, y dos tópicos (2 y 8) son mezclas que no deben citarse como tema.
- RCN tiene fecha exacta sólo desde 2020-09, y el volumen de cada medio depende de sus sitemaps.

6.3. Mejoras futuras

1. Que una segunda persona anote la planilla 2 o adjudique los 32 desacuerdos, para tener un κ entre humanos.
2. Un silver standard centrado en los titulares sobre el gobierno, con $\sim$100 por celda, para bajar los IC por medio a $\pm$10–15 pp.
3. Medir el recall del emparejamiento anotando ausencias, y calibrar el umbral del seguimiento.
4. Una grilla de k para BERTopic, extenderlo al corpus completo y validar sus tópicos con una prueba de intrusión de palabras.

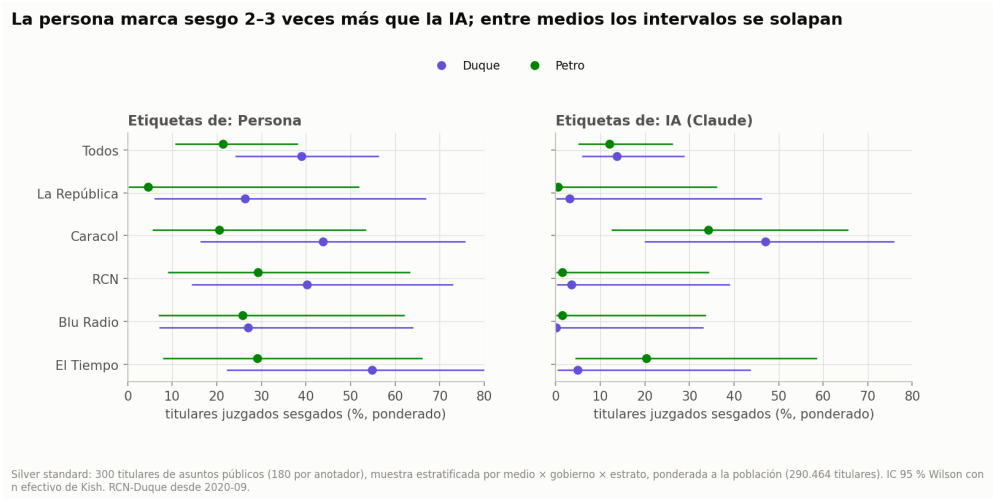


Figura 6: Tasa de titulares juzgados sesgados por medio y gobierno, según cada anotador, ponderada a la población, IC 95 %.

5. Usar el titular publicado o el texto completo en una submuestra, para recuperar las comillas y la atribución.

VII. CONCLUSIONES

Con 1,57 millones de titulares y tres niveles de análisis, las diferencias entre los cinco medios son pequeñas y sobre todo de perfil y estilo, y esos perfiles se mantienen entre gobiernos. Lo que cambia con Petro es común a todos: más asuntos públicos, más personalización y más carga negativa sobre el gobierno. Eso apunta a un cambio del periodo más que a decisiones editoriales de un medio. Los cambios propios de cada medio son pocos y modestos: Caracol cubre más Venezuela y menos policía, RCN más justicia, y El Tiempo personaliza más. Ninguno equivale a un trato sistemáticamente más duro con un gobierno.

En lo metodológico, BERTopic es el único modelo de tópicos estable sobre titulares, y el umbral calibrado a mano permite comparar el mismo hecho con una precisión conocida. El silver standard deja una lección: la carga léxica no equivale a sesgo juzgado. Cualquier afirmación sobre el sesgo de un medio a partir de indicadores automáticos de titulares debe tomarse con cautela.

Reproducibilidad

El código, los datos procesados y los scripts están en `entrega3/`. Hay imágenes Docker (`duque-petro-lda` y `duque-petro-bertopic`) y etapas reproducibles con `./run.sh`. Se usan las semillas 42, 7 y 123, y `config.json` guarda el SHA-256 del input. El código tiene 100 funciones de prueba. El detalle de cada paso está en `entrega3/README.md` y en `entrega3/INFORME_FINAL.md`.

Referencias

[1] R. Entman. Framing: Toward Clarification of a Fractured Paradigm. *Journal of Communication*, 43(4), 51–58, 1993.

[2] F. Hamborg, K. Donnay y B. Gipp. Automated identification of media bias in news articles: an interdisciplinary literature review. *International Journal on Digital Libraries*, 20, 391–415, 2019.

[3] F. Hamborg. Media Bias, the Social Sciences, and NLP: Automating Frame Analyses to Identify Bias by Word Choice and Labeling. *ACL Student Research Workshop*, 2020.

[4] D. Blei, A. Ng y M. Jordan. Latent Dirichlet Allocation. *Journal of Machine Learning Research*, 3, 993–1022, 2003.

[5] M. Röder, A. Both y A. Hinneburg. Exploring the Space of Topic Coherence Measures. *WSDM*, 399–408, 2015.

[6] M. Grootendorst. BERTopic: Neural topic modeling with a class-based TF-IDF procedure. arXiv:2203.05794, 2022.

[7] N. Reimers e I. Gurevych. Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks. *EMNLP-IJCNLP*, 2019.

[8] N. Reimers e I. Gurevych. Making Monolingual Sentence Embeddings Multilingual using Knowledge Distillation. *EMNLP*, 2020.

[9] L. McInnes, J. Healy y J. Melville. UMAP: Uniform Manifold Approximation and Projection for Dimension Reduction. arXiv:1802.03426, 2018.

[10] H. Künsch. The Jackknife and the Bootstrap for General Stationary Observations. *The Annals of Statistics*, 17(3), 1217–1241, 1989.

[11] S. Holm. A Simple Sequentially Rejective Multiple Test Procedure. *Scandinavian Journal of Statistics*, 6(2), 65–70, 1979.

[12] J. Cohen. A Coefficient of Agreement for Nominal Scales. *Educational and Psychological Measurement*, 20(1), 37–46, 1960.

[13] B. Monroe, M. Colaresi y K. Quinn. Fightin' Words: Lexical Feature Selection and Evaluation for Identifying the Content of Political Conflict. *Political Analysis*, 16(4), 372–403, 2008.

[14] Y. Benjamini e Y. Hochberg. Controlling the False Discovery Rate: A Practical and Powerful Approach to Mul-

tiple Testing. *Journal of the Royal Statistical Society B*, 57(1), 289–300, 1995.

[15] E. Wilson. Probable Inference, the Law of Succession, and Statistical Inference. *Journal of the American Statistical Association*, 22(158), 209–212, 1927.

[16] L. Kish. *Survey Sampling*. Wiley, 1965.

[17] J. Grimmer y B. Stewart. Text as Data: The Promise and Pitfalls of Automatic Content Analysis Methods for Political Texts. *Political Analysis*, 21(3), 267–297, 2013.