# Detección de sesgo mediático mediante análisis de framing: EDA avanzado, representación y propuesta metodológica sobre prensa colombiana (2018–2022)

Abel Albuez Sanchez, Kelly Joane Leon Torres, Juan Camilo Torres Peña, Jesús David Romero Melo
*Maestría en Ingeniería de Sistemas y Computación, Pontificia Universidad Javeriana, Bogotá D.C., Colombia*
Procesamiento de Lenguaje Natural, 2026 — Entrega 2

## Resumen

*Esta entrega analiza 708 768 registros publicados por seis medios colombianos durante el gobierno de Iván Duque (7 de agosto de 2018 a 6 de agosto de 2022), con 707 553 titulares reconstruidos desde la URL. Se reportan textometría (Zipf, diversidad léxica con rarefacción, n-gramas), cobertura temática por palabras clave con pruebas $\chi^2$ y tamaño de efecto, y un modelado de tópicos LDA sobre el corpus completo. Las diferencias entre medios son estadísticamente significativas pero pequeñas (V de Cramér entre 0,015 y 0,059), y el análisis es exploratorio: no confirma ni descarta sesgo editorial. Se comparan representaciones del texto (BoW, TF-IDF, distribuciones de tópicos y embeddings) y se propone una metodología de modelado por dimensión del sesgo, con comparación de clasificadores en cascada frente a LLM ajustados.*
**Index Terms**— media bias, framing analysis, exploratory data analysis, topic modeling, text representation, Spanish NLP, Colombian news.

## I. CORRECCIONES RESPECTO A LA ENTREGA 1

La Entrega 1 documentó la idea, el estado del arte y un prototipo probado sobre un evento con tres artículos de medios ficticios. El corpus histórico estaba en construcción y no se reportaron cifras. La Tabla 1 resume los ajustes y sus razones.

### 1.1. Correcciones internas de esta entrega

Una auditoría reproducible (46 verificaciones automáticas aprobadas) corrigió tres afirmaciones de borradores previos:

- **Diversidad.** No se sostiene que La República sea «35 % más diversa». Con igual número de tokens es, de hecho, el medio con menor TTR (Sección 2.4).
- **Tópicos LDA.** Las etiquetas temáticas («economía», «seguridad») no correspondían a los términos del modelo. Aquí se reportan los términos verificados contra el modelo guardado (Sección 2.8).
- **Cambio.** Sus 98 registros son una ventana de seis días, no una muestra de cuatro años. Se excluye de las comparaciones.

### 1.2. Construcción del corpus

La base unificada `news_corpus` se construyó recorriendo los sitemaps mensuales de cada medio. El corte Duque se exportó a Parquet con suma de verificación SHA-256, y el análisis lee esa exportación en modo de solo lectura, sin consultar la base. Los sitemaps históricos no incluyen el titular, por lo que este se reconstruye desde la URL: `.../reforma-tributaria-ya-fue-radicada-ante-el-congreso-...` se convierte en «Reforma tributaria ya fue radicada ante el congreso». Se pierden tildes, puntuación, comillas y cambios posteriores del titular.

La fecha tiene precisión de día en 670 147 registros y solo de mes en 38 621. Parte de las fechas de día proviene del `lastmod` del sitemap, que es la fecha de modificación y no necesariamente la de publicación.

## II. ANÁLISIS EXPLORATORIO AVANZADO

### 2.1. Preprocesamiento

**Fundamento.** Cada decisión de preprocesamiento es una hipótesis sobre qué variación es ruido y cuál es señal [1]. Aquí la hipótesis central es que tildes, mayúsculas y puntuación son ruido, porque todos los titulares provienen del *slug*.

- **Normalización.** Descomposición Unicode (NFD) y eliminación de marcas diacríticas: «Nariño» y «NARINO» quedan como *narino*. Se eliminan URLs y se conservan solo secuencias alfabéticas.
- **Palabras vacías.** La ley de Zipf [2] predice que unas pocas palabras funcionales concentran gran parte de los tokens. Se eliminan las *stopwords* del español de NLTK y los verbos de reporte («dijo», «dice», «expresó»), y los tokens de dos letras o menos.

**Tabla 1:** Correcciones y modificaciones respecto a la Entrega 1.

| Aspecto | Entrega 1 | Entrega 2 | Razón |
|---|---|---|---|
| **Corpus** | Un evento, tres medios ficticios (`corpus_ejemplo.json`). | 708 768 registros reales del gobierno Duque, seis medios, más una base unificada que también contiene el gobierno Petro. | El ejemplo servía para probar el prototipo, no para describir medios reales. |
| **Ventana** | 2006–2026, cinco gobiernos. | Corte Duque: 2018-08-07 a 2022-08-06 (intervalo semiabierto hasta el 7 de agosto). | Un gobierno completo con cinco medios y cuatro años comparables; el corte Petro se recolectó por separado. |
| **Medios** | Diez catalogados. | Cinco series principales (El Tiempo, Blu Radio, Caracol, La República, RCN). Cambio aporta solo 98 registros y se analiza aparte. | Cambio solo tiene archivo desde agosto de 2022; seis días caen en el corte. |
| **Unidad** | Texto completo; medidas por oración. | Titular reconstruido desde la URL (*slug*). | No hay cuerpos HTML en el corte; el titular cubre el 99,8 % de los registros. |
| **Limpieza** | Normalizar espacios; conservar términos originales. | Minúsculas, sin tildes, palabras alfabéticas de más de dos letras, *stopwords* y verbos de reporte. | El *slug* ya llega sin tildes ni puntuación; normalizar todo evita confundir procedencia con diferencia entre medios. |
| **Medidas** | Previstas sin cifras. | Zipf, TTR con rarefacción, MSTTR, $K$ de Yule, n-gramas, tasas temáticas con $\chi^2$, Holm y $V$ de Cramér, LDA. | Pendiente explícito de la Entrega 1. |
| **Inferencia** | — | Se reporta el tamaño de efecto junto al valor $p$, y los límites de independencia. | Con $N \approx 7 \cdot 10^5$ casi todo es significativo; el efecto dice si importa. |
| **Evento** | `evento_id` manual. | Casos temporales con URL para comprobación humana y similitud entre representaciones (Sección IV). | Asignar eventos a mano es inviable a esta escala. |

**Tabla 2:** Corpus del corte Duque por medio. *Palabras*: tokens de contenido por titular.

| Medio | Registros | Titulares | Palabras | Desde |
|---|---|---|---|---|
| El Tiempo | 263 145 | 262 968 | 6,04 | 2018-08 |
| Blu Radio | 166 593 | 165 916 | 7,13 | 2018-08 |
| Caracol | 109 384 | 109 085 | 7,44 | 2018-08 |
| La República | 91 801 | 91 743 | 6,79 | 2018-08 |
| RCN | 77 747 | 77 743 | 6,73 | 2018-09 |
| Cambio | 98 | 98 | 4,86 | 2022-08 |
| **Total** | **708 768** | **707 553** | | |

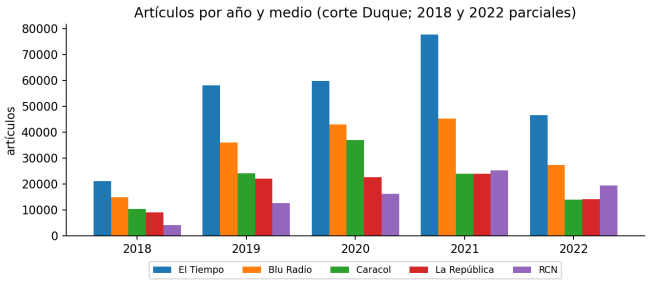



**Figura 1:** Artículos por año y medio en el corte Duque.

- **Lo que se conserva.** Nombres de actores y lugares, porque son información sobre qué cubre cada medio.

## 2.2. Descripción del corpus

El Tiempo aporta el 37 % de los registros (Tabla 2, Figura 1). El volumen anual crece hasta 2021 en casi todos los medios; 2018 y 2022 son años parciales. Hay 32 368 registros que comparten titular normalizado con otro, en su mayoría formatos repetidos (programas, emisiones, resultados de lotería). Esto viola la independencia que suponen las pruebas estadísticas y hace sus intervalos demasiado optimistas.

## 2.3. Ley de Zipf

**Fundamento.** La ley de Zipf [2] establece que la frecuencia $f$ de una palabra es aproximadamente inversa a su rango $r$, $f(r) \propto r^{-\alpha}$ con $\alpha \approx 1$. En escala log-log esto es una recta de pendiente $-\alpha$. Verificarla indica que el

**Tabla 3:** Diversidad léxica. TTR con rarefacción (10 000 tokens, 100 submuestras; entre corchetes, cuantiles 2,5–97,5 del procedimiento).

| Medio | TTR (rarefacción) | $\text{MSTTR}_{50}$ | $K$ Yule |
|---|---|---|---|
| Caracol | 0,480 [0,473–0,489] | 0,958 | 8,80 |
| El Tiempo | 0,476 [0,470–0,484] | 0,954 | 7,35 |
| Blu Radio | 0,469 [0,462–0,476] | 0,960 | 7,57 |
| RCN | 0,453 [0,444–0,461] | 0,957 | 8,17 |
| La República | 0,447 [0,440–0,455] | 0,972 | 7,77 |

corpus se comporta como lenguaje natural; desviaciones fuertes delatan texto repetitivo o generado por plantillas.

**Resultados.** Sobre 4 737 325 tokens y 98 418 palabras distintas, el ajuste en los rangos 10 a 10 000 da $r = -0{,}982$, pendiente $-1{,}035$ y $R^2 = 0{,}969$. Los cinco medios principales tienen pendientes entre $-1{,}03$ y $-1{,}11$ y $R^2$ entre 0,969 y 0,972; Cambio, con solo 476 tokens, no es comparable. Este ajuste es descriptivo: rango y frecuencia están ordenados por construcción, y certificar una ley de potencia exigiría pruebas de bondad de ajuste contra distribuciones alternativas [3].

## 2.4. Diversidad léxica

**Fundamento.** Sea $N$ el número de tokens, $V$ el de palabras distintas y $f_i$ la frecuencia de la palabra $i$. La razón tipo/token $\text{TTR} = V/N$ disminuye con la longitud del texto, porque el vocabulario crece más despacio que el texto (ley de Heaps [4]). Por eso medios de distinto tamaño no se comparan con el TTR agregado [5]. Se usaron tres estrategias:

- **Rarefacción:** 100 submuestras aleatorias sin reemplazo de 10 000 tokens por medio; se reporta el TTR medio y los cuantiles 2,5 y 97,5. Iguala el presupuesto de tokens, pero no controla género ni agenda.
- **MSTTR:** el TTR promedio de segmentos completos de 50 tokens, descartando el segmento final incompleto.
- $K$ **de Yule** [6]: $K = 10^4 \sum_i f_i(f_i - 1)/N^2$, la probabilidad de que dos tokens tomados al azar sean la misma palabra. Menor $K$ indica mayor diversidad.

**Resultados.** Con igual número de tokens, Caracol y El Tiempo tienen el TTR más alto (0,480 y 0,476) y La República el más bajo (0,447): la diferencia es de unos 3 puntos (Tabla 3, Figura 2). El orden cambia con MSTTR, donde La República es la más alta (0,972). En la comparación mensual pareada, La República supera a El Tiempo en 0,018 de MSTTR [0,015–0,021] en los 48 meses. Que dos medidas ordenen distinto a los medios muestra que capturan propiedades diferentes: la rarefacción mezcla titulares de todo el corpus, mientras que MSTTR mide la variedad dentro de tramos consecutivos. Ninguna mide calidad de escritura ni encuadre.

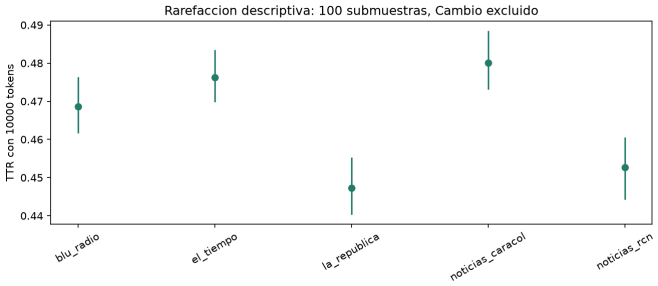



**Figura 2:** TTR con rarefacción a 10 000 tokens por medio (Cambio excluido).

**Tabla 4:** Bigramas más distintivos por medio (por 1 000 titulares).

| Medio | Bigramas |
|---|---|
| Blu Radio | programa completo (53,2), blu programa (19,2), voz populi (13,3) |
| El Tiempo | caricatura matador (7,0), selección colombia (6,6), editorial tiempo (6,1) |
| La República | dólar petróleo (7,2), américa latina (6,5), reino unido (6,0) |
| Caracol | video noticias (9,7), pico placa (6,6), claudia lópez (5,9) |
| RCN | pico placa (11,8), emisión martes (8,2), emisión miércoles (8,0) |

## 2.5. N-gramas

**Fundamento.** Un n-grama es una secuencia de $n$ palabras consecutivas. Los bigramas y trigramas capturan unidades que no se reducen a palabras sueltas: nombres propios (*iván duque*), términos (*reforma tributaria*) y fórmulas recurrentes (*pico y placa*). En este análisis se forman después de retirar las *stopwords*, así que dos palabras contiguas en la lista pueden no serlo en el titular original. Para comparar medios de distinto tamaño se reportan por cada 1 000 titulares.

**Resultados.** Los bigramas más frecuentes del corpus mezclan agenda y formato: *programa completo* (8 822), *selección colombia* (2 901), *claudia lópez* (2 881), *iván duque* (2 738), *coronavirus colombia* (2 686), *pico placa* (2 664) y *gustavo petro* (2 516). Por medio (Tabla 4), los n-gramas más distintivos son de formato: los programas de Blu Radio, las emisiones de RCN, la caricatura y el editorial de El Tiempo. Solo La República destaca por un tema (dólar, petróleo, economía regional). La lección metodológica es que, antes de comparar encuadres, hay que separar géneros (noticia, programa, opinión, servicio): de lo contrario se compara la oferta de productos de cada portal.

## 2.6. Recursos léxicos: tesauros y ontologías

**Fundamento.** Un recurso léxico representa conocimiento sobre las palabras y aquello a lo que se refieren. De menor a mayor estructura:

- **Vocabulario controlado:** lista de términos autorizados, sin relaciones.
- **Tesauro:** organiza conceptos con un término preferente, términos alternativos y relaciones jerárquicas y asociativas (ISO 25964 [7]; en la web, SKOS [8]).
- **Ontología:** una «especificación explícita de una conceptualización» [9], que distingue clases de instancias y puede declarar propiedades entre ellas [10].

Aplicar estos recursos es un *método de diccionario*: un texto recibe una categoría si contiene alguno de sus términos. Es transparente, porque cada asignación se explica por el término que la produjo, pero su validez debe comprobarse sobre el corpus concreto [11].

**Recursos usados.** En el corte Duque se aplicaron dos:

- **Lista de palabras vacías:** las *stopwords* del español de NLTK, ampliadas con verbos de reporte.
- **Vocabulario controlado de tres temas** (Reforma tributaria, Conflicto armado y Corrupción): términos como *impuesto*, *violencia* o *fraude*. Las listas completas están en el script de análisis.

El proyecto cuenta además con un tesauro de 7 temas y 35 subtemas (`topics.yaml`) y una ontología de 11 clases y 51 actores con 204 alias (`actores.yaml`), construidos sobre el corte 2022–2026. Su aplicación al corte Duque requiere ajustar los actores al período (por ejemplo, el gabinete de Duque) y queda como paso siguiente.

## 2.7. Cobertura temática y coocurrencias

**Fundamento.** La teoría de la agenda (*agenda-setting*) sostiene que los medios no determinan qué piensa el público, pero sí sobre qué piensa [12]. Comparar qué proporción de sus titulares dedica cada medio a un tema es una primera aproximación a esa selección. Para cada tema se cuenta qué proporción de los titulares de cada medio contiene alguna de sus palabras clave, con intervalo de Wilson [13]. La asociación se prueba con un $\chi^2$ sobre una tabla de 5 medios $\times$ 2 estados (con o sin palabra clave), se corrige por comparaciones múltiples con Holm [14] y se reporta la $V$ de Cramér como tamaño de efecto:

$$V = \sqrt{\frac{\chi^2}{N\,(\min(r,c)-1)}}. \qquad (1)$$

**Resultados.** Las tres asociaciones son significativas tras Holm, pero con efectos muy pequeños ($V$ entre 0,015 y 0,049; Tabla 5, Figura 3). La República tiene la mayor tasa de reforma tributaria (1,08 %) y la menor de conflicto armado (0,10 %); Blu Radio y RCN, la mayor de conflicto (1,97 %). Con $N$ tan grande, el valor $p$ diminuto no implica un efecto sustantivo, y la dependencia entre titulares repetidos hace la prueba demasiado optimista. Estas cifras son coincidencias de palabras clave, no mediciones de cobertura completa ni de postura.

**Tabla 5:** Porcentaje de titulares con palabras clave de cada tema, y prueba $\chi^2$ (5 medios, $N = 707\,455$).

| Medio | Reforma trib. | Conflicto | Corrupción |
|---|---|---|---|
| Blu Radio | 0,42 | **1,97** | **0,67** |
| El Tiempo | 0,41 | 1,33 | 0,44 |
| La República | **1,08** | 0,10 | 0,35 |
| Caracol | 0,32 | 1,66 | 0,51 |
| RCN | 0,37 | **1,97** | 0,53 |
| $\chi^2$ | 819,4 | 1 702,3 | 162,2 |
| $p$ (Holm) | $< 10^{-170}$ | $< 10^{-300}$ | $< 10^{-33}$ |
| $V$ de Cramér | 0,034 | 0,049 | 0,015 |

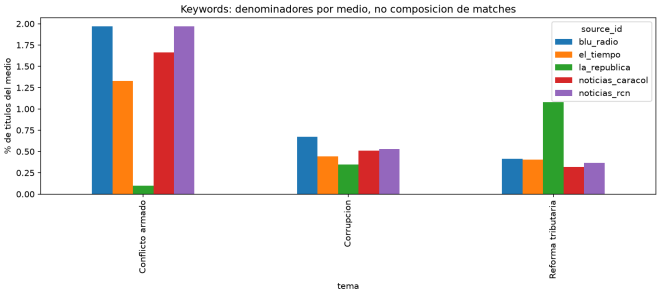



**Figura 3:** Porcentaje de titulares con palabras clave por tema y medio.

**Casos temporales.** En ventanas acotadas alrededor de hechos concretos cambia la escala. Durante la reforma tributaria y el paro de 2021, el 5,3 % de los titulares de El Tiempo y Caracol tocó el tema, frente al 1,3 % de La República. En el bombardeo con menores de 2019 la tasa va de 2,6 % (Caracol) a 0,1 % (La República), y en el caso Centros Poblados (2021), de 1,9 % (Caracol) a 0,6 % (La República). Cada caso conserva las URL de ejemplo para comprobación humana.

**Coocurrencias con cada tema.** Para cada medio se identificaron las palabras que más coocurren con las palabras clave del tema, frente a los demás medios (log-odds descriptivo, sin prueba de significancia). En reforma tributaria, La República asocia el tema con *pib*, *censo*, *méxico* y *chile* (lectura macroeconómica y regional); El Tiempo, con *columna* y *entrevista* (géneros de opinión); y Blu Radio, con nombres propios, regiones (*bucaramanga*, *antioquia*) y *opinión*. En conflicto armado, RCN coocurre con *detienen*, *vínculos* y *prontuario*, y Caracol con *video*, *mataron* y *magnicidio*: vocabulario policial y de sucesos, una pista para el análisis de encuadre de la Sección V.

**Tabla 6:** Selección de $K$: coherencia $c_v$ y perplejidad de entrenamiento.

| $K$ | $c_v$ | Perplejidad (base 2) |
|---|---|---|
| 3 | 0,313 | 328 |
| **5** | **0,360** | 391 |
| 7 | 0,339 | 415 |
| 10 | 0,332 | 442 |
| 15 | 0,309 | 8 678 |

## 2.8. Modelado de tópicos (LDA)

**Fundamento.** LDA [15] supone que cada documento es una mezcla de $K$ tópicos y que cada tópico es una distribución sobre las palabras. El modelo infiere, para cada documento $d$, un vector $\theta_d$ de proporciones de tópicos, y para cada tópico $k$ una distribución $\beta_k$ sobre el vocabulario. Es un método no supervisado: descubre temas que ningún diccionario previó. Para elegir $K$ se usó la coherencia $c_v$ [16], que mide si las palabras principales de cada tópico coocurren en el corpus y se asocia con la interpretabilidad humana. La perplejidad mide el ajuste, pero no garantiza tópicos interpretables.

**Configuración.** Se entrenaron $K \in \{3, 5, 7, 10, 15\}$ sobre los 706 083 documentos con vocabulario útil (no una muestra), con un diccionario de 10 000 términos que aparecen en al menos 10 documentos, 10 pasadas, 50 iteraciones y semilla 42.

**Resultados.** $K = 5$ obtuvo la mayor coherencia (0,360), con una ventaja de 0,020 sobre $K = 7$ (Tabla 6, Figura 4). No se midió la variabilidad entre semillas, así que esa ventaja no está validada estadísticamente. Los términos de cada tópico, verificados contra el modelo guardado, son:

- **T0:** emisión, bogotá, martes, jueves, nacional, miércoles, lunes, elecciones (programación y emisiones).
- **T1:** covid, colombia, bogotá, años, coronavirus, personas, millones (pandemia y noticias generales).
- **T2:** colombia, duque, ucrania, unidos, presidente, rusia, gobierno, venezuela (política nacional e internacional).
- **T3:** colombia, así, video, pico, placa, américa, mundial (movilidad, video y deportes).
- **T4:** petro, gustavo, luis, caso, díaz, covid, fiscalía (actores políticos y deportivos, casos judiciales).

Las etiquetas entre paréntesis son lecturas orientativas, no clasificaciones validadas. Los tópicos mezclan agenda y formato (T0, T3): con titulares de unas 7 palabras y géneros mezclados, LDA captura tanto el tipo de producto como el tema.

**Perfiles por medio.** La distribución del tópico dominante no es uniforme entre medios (Figura 5): Caracol concentra el 36,9 % de sus titulares en T1 (pandemia y generales), El Tiempo el 27,8 % en T3 y La República el 21,5 % en T2. Un $\chi^2$ de 5 medios $\times$ 5 tópicos da $\chi^2 = 9\,887$ (16 g. l.) y $V = 0{,}059$: asociación significativa pero pequeña.

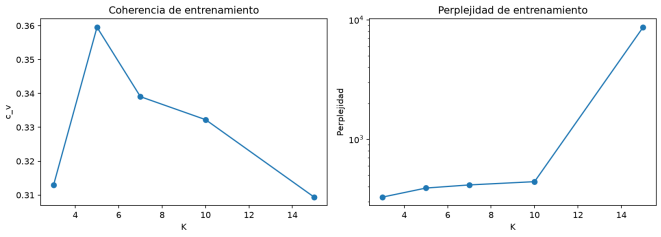



**Figura 4:** Coherencia $c_v$ y perplejidad de entrenamiento según $K$.

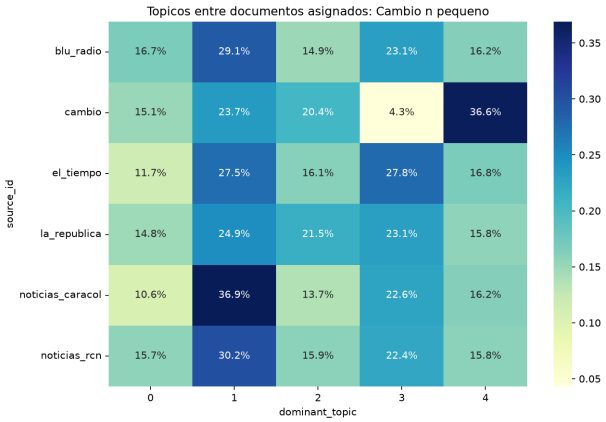



**Figura 5:** Distribución del tópico dominante por medio (documentos asignados).

Para medir la cercanía entre perfiles se usó la distancia de Jensen-Shannon [17], que es simétrica y está acotada entre 0 y 1 con logaritmo en base 2. Blu Radio y RCN son los medios más parecidos (0,018), y Caracol (0,074) y La República (0,067) los más alejados del perfil promedio. El dendrograma correspondiente (anexo de resultados) es descriptivo: no se validaron agrupamientos ni deben leerse como bloques ideológicos.

**Confianza de las asignaciones.** 2 685 documentos quedan sin tópico (su vocabulario no está en el diccionario) y 26 282 (3,7 % de los asignados) tienen un tópico dominante con probabilidad menor de 0,3, frente a 0,2 de una asignación uniforme. La confianza media es 0,49. Se conservan los 40 ejemplos menos confiables, con su URL, para revisión manual.

# III. CONJUNTO DE DATOS MEDIDO

Los resultados se entregan en `entrega2/`, en formatos legibles (Parquet y CSV), con suma de verificación del insumo y un registro de las versiones de las librerías:

- `resultados/document_topics.parquet` (708 768 filas): un registro por artículo con `article_id`, `source_id`, `published_date`, `year`,

`date_precision`, `title_source`, `dominant_topic` y `topic_confidence`.

- `resultados/diversidad_documentos.parquet` (708 768 filas): `num_tokens`, `ttr`, `msttr_titulo` y `yule_k` por titular.
- **Tablas de métricas:** frecuencias, bigramas, trigramas, diversidad por medio, cobertura temática, casos temporales con ejemplos y URL, contrastes léxicos y la grilla LDA.
- **Modelos:** diccionario, corpus en formato Matrix Market y modelos LDA para cada $K$ (`resultados/modelos/`).
- **Trazabilidad:** `research/DATA_INSIGHTS_TABLES.csv` (90 métricas en formato largo) y `research/audit_checks.csv` (46 verificaciones aprobadas).

El titular normalizado y sus tokens se generan de forma determinista con `core.tokenize` a partir del Parquet de entrada; el notebook ejecutado (`entrega2.ipynb`) documenta cada paso.

# IV. REPRESENTACIÓN DE LOS TEXTOS

## 4.1. Selección y justificación

Representar un texto es asignarle un vector numérico sobre el que se pueda calcular. Cada representación decide qué información conserva, y cada una responde a una necesidad distinta del proyecto:

- **Bolsa de palabras (BoW):** la línea base interpretable. El sesgo por selección léxica [18, 19] se expresa precisamente en qué palabras se eligen, y es la entrada del modelo LDA de la Sección 2.8.
- **TF-IDF:** pondera cada palabra por su especificidad y permite comparar titulares cortos. Es la base para buscar coberturas del mismo hecho.
- **Distribución de tópicos ($\theta_d$ de LDA):** un vector denso de 5 dimensiones que resume de qué trata un titular. Sirve para comparar perfiles de cobertura entre medios.
- **Embeddings de palabras y contextuales:** capturan similitud semántica más allá de las palabras compartidas; son necesarios para reconocer paráfrasis entre medios.

## 4.2. Fundamentos

**BoW.** Un titular $d$ es un vector con una dimensión por palabra del diccionario (10 000 términos), cuyo valor es la frecuencia $\mathrm{tf}(t, d)$. Ignora el orden, pero conserva qué palabras se eligieron.

**TF-IDF** [20, 21]. Una palabra presente en casi todos los titulares (*colombia*) no distingue a ninguno; una presente en pocos (*iglesias*) caracteriza a los que la contienen. En la variante usada (`gensim`):

$$w_{t,d} = \mathrm{tf}(t, d) \cdot \log_2 \frac{N}{\mathrm{df}(t)}, \tag{2}$$

con $N = 708\,768$ documentos y $\mathrm{df}(t)$ el número de documentos que contienen $t$. Cada vector se normaliza a norma euclidiana 1, y la similitud entre titulares es el coseno, que va de 0 a 1 porque los pesos no son negativos. Por ejemplo, $\mathrm{idf}(\textit{colombia}) = 4{,}0$, $\mathrm{idf}(\textit{duque}) = 6{,}1$, $\mathrm{idf}(\textit{reforma}) = 8{,}2$ e $\mathrm{idf}(\textit{iglesias}) = 11{,}4$.

**Distribución de tópicos.** El LDA ajustado asigna a cada titular un vector $\theta_d \in [0, 1]^5$ que suma 1. Es denso y de baja dimensión, pero con textos tan cortos la inferencia es incierta: un titular de cinco palabras aporta poca evidencia para estimar cinco proporciones.

**Embeddings.** El modelo *skip-gram* [22] aprende un vector denso por palabra prediciendo las palabras de su contexto; FastText le añade n-gramas de caracteres, lo que permite representar palabras no vistas y variantes sin tildes [23]. Los modelos contextuales como Sentence-BERT [24] producen un vector por oración que depende del contexto, y reconocen paráfrasis sin palabras en común.

## 4.3. Ejemplos sobre el corpus

La Tabla 7 transforma tres titulares reales del 15 de abril de 2021, día de la radicación de la reforma tributaria, con el diccionario y el modelo LDA del corte Duque.

Tres observaciones se desprenden del ejemplo:

- **BoW y TF-IDF son escasos.** Cada titular activa entre 4 y 9 de las 10 000 dimensiones. TF-IDF da más peso a lo específico de cada titular (*paguen*, *reaccionan*) que a lo compartido (*reforma tributaria*).
- **La distribución de tópicos es poco informativa en titulares cortos.** El de Blu Radio se asigna sobre todo a T0 (emisiones) y el de Caracol reparte su masa entre cuatro tópicos: con textos tan cortos los tópicos no separan bien.
- **TF-IDF recupera el mismo hecho entre medios.** Entre los 15 titulares de ese día, los dos más similares son de medios distintos: «Reforma tributaria: Duque pide al Congreso apoyo para aprobarla» (Blu Radio) y «Reforma tributaria ya fue radicada ante el Congreso de la República» (RCN), con coseno 0,62. La similitud media entre los demás pares fue de alrededor de 0,3.

## 4.4. Embeddings evaluados en el corte 2022–2026

Sobre el corte del gobierno Petro (916 452 noticias de los mismos medios más Cambio, con el

**Tabla 7:** Tres titulares del 15 de abril de 2021 transformados con el diccionario y el modelo LDA ($K = 5$) del corte Duque.

| Titular (medio) | BoW (tokens con valor 1) | TF-IDF (pesos más altos) | $\theta_d$ (T0–T4) |
|---|---|---|---|
| «Reforma tributaria propondría que estratos 4 al 6 paguen IVA...» (Blu Radio) | reforma, tributaria, estratos, paguen, iva, servicios, públicos | paguen 0,48 · estratos 0,45 · públicos 0,36 · servicios 0,34 | (0,53; 0,03; 0,15; 0,28; 0,03) |
| «Políticos reaccionan a la radicación de la reforma tributaria» (El Tiempo) | políticos, reaccionan, reforma, tributaria | reaccionan 0,63 · políticos 0,49 · tributaria 0,45 · reforma 0,41 | (0,04; 0,04; 0,04; 0,64; 0,24) |
| «Si vamos a subir el IVA es necesario devolvérselo a los pobres: experto...» (Caracol) | vamos, subir, iva, necesario, pobres, experto, analiza, reforma, tributaria | necesario 0,38 · pobres 0,37 · subir 0,36 · analiza 0,36 | (0,22; 0,22; 0,12; 0,32; 0,12) |

mismo preprocesamiento) se entrenó FastText (*skip-gram*, 100 dimensiones). Sus vecinos reflejan relaciones semánticas del período: *eln* → *disidencias*, *farc*, *guerrilla*; *inflación* → *desinflación*, *estanflación*; *corrupción* → *anticorrupción*, *escándalo*. La proyección t-SNE [25] de esa representación agrupó los titulares por tema y los mezcló por medio. Sobre el mismo corte, TF-IDF recuperó la cobertura del aval fiscal de la reforma pensional (octubre de 2023) en cuatro medios, cada uno con un encuadre distinto («dio el aval fiscal», «sería completamente financiable», «valdrá más», «deuda impagable»).

### 4.5. Elección

TF-IDF se mantiene como representación principal para los análisis léxicos y la recuperación del mismo hecho, por ser interpretable y eficaz con titulares cortos. La distribución de tópicos se usa solo para perfiles agregados por medio, no para clasificar titulares individuales. Para agrupar coberturas por evento y para los clasificadores de la Sección V se usarán embeddings contextuales, porque la paráfrasis entre medios es la norma.

## V. PROPUESTA METODOLÓGICA

### 5.1. Enfoque general

El sesgo se mide en cuatro dimensiones, cada una con una tarea de PLN propia [18]: qué palabras se eligen (A), a quién se cita (B), qué se enfatiza u omite (C) y cómo se enmarca el hecho (D) [26]. La distinción central del proyecto es que el tono emocional depende del hecho, mientras que el sesgo depende de cómo se cuenta. Por eso ningún medio se compara con otro fuera de un mismo evento, y la carga emocional se trata como variable de control y no como objetivo (Figura 6).

La Tabla 8 resume el enfoque de modelado de cada dimensión.

### 5.2. Dimensión A: qué palabras se eligen

**Enfoque.** Clasificación supervisada de cada oración como descriptiva o valorativa, con una segunda salida que marca etiquetas ideológicas.

**Justificación.** La subjetividad es un fenómeno de la oración: un adjetivo valorativo o una opinión presentada como hecho cambian una frase, no un artículo entero. Existe un corpus anotado de sesgo en prensa en español, el MBBMD [27], que permite ajustar modelos antes de anotar el corpus propio. Un diccionario no basta: en la revisión manual del lexicón del proyecto, «guerrilleros» se contaba como etiqueta ideológica cuando solo describía a un grupo armado.

**Modelos.** (1) Regresión logística sobre TF-IDF más conteos del lexicón; (2) BETO [28] o RoBERTa-BNE [29], ajustados primero en el MBBMD y luego en las oraciones anotadas; (3) un LLM con instrucciones, siguiendo la metodología de Salas-Jiménez et al. [30].

### 5.3. Dimensión B: a quién se cita

**Enfoque.** Cascada de dos etapas: extracción de atribuciones (quién habla, si es cita directa o indirecta, y a qué clase de la ontología de actores pertenece) y clasificación de la postura del hablante (a favor, en contra o neutral).

**Justificación.** Dar cita directa a un actor lo legitima; relatarlo en tercera persona lo distancia [31, 32]. Burnham muestra que postura y sentimiento son distintos: un actor puede apoyar una reforma con lenguaje negativo hacia la oposición [32]. Esta dimensión requiere el cuerpo del artículo, que el corpus de titulares no tiene.

**Modelos.** (1) Reglas: comillas, verbos de atribución y alias de la ontología; (2) etiquetado de secuencias para el hablante más un clasificador de postura basado en inferencia de lenguaje natural [32]; (3) un LLM con aprendizaje en contexto guiado por criterios periodísticos [31]. Para comparar medios se usa el coeficiente de Gini de la distribución de citas por clase de actor $x_i$:

$$G = \frac{\sum_i \sum_j |x_i - x_j|}{2\, n^2\, \bar{x}}, \tag{3}$$

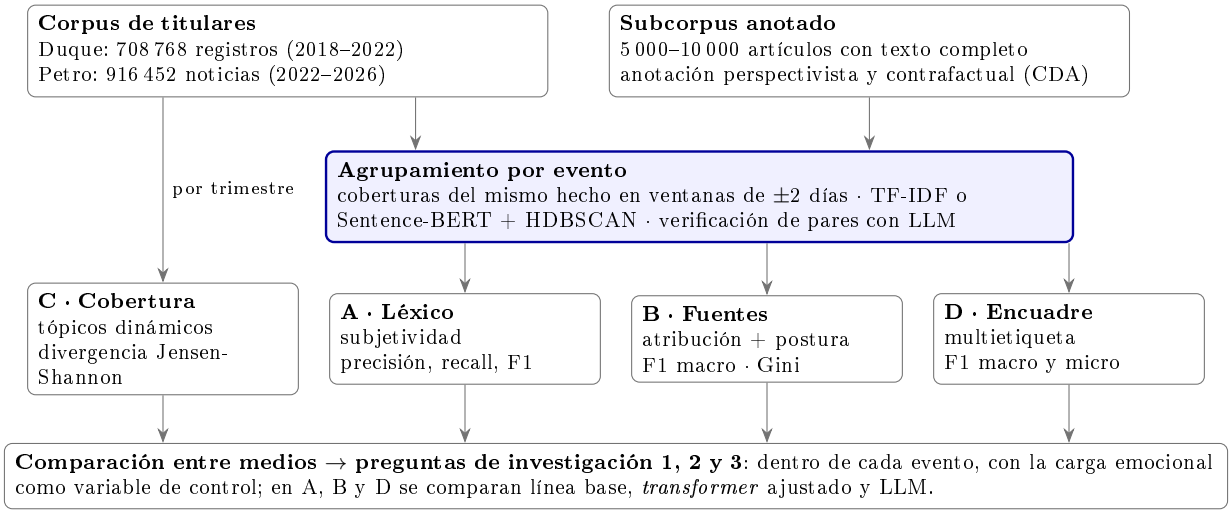



**Figura 6:** Arquitectura de la propuesta: dos fuentes de datos, agrupamiento por evento y una tarea de modelado por dimensión del sesgo.

**Tabla 8:** Enfoque de modelado por dimensión del sesgo.

| Dimensión | Tipo de modelado | Datos | Métrica |
|---|---|---|---|
| **A · Léxico** | Clasificación supervisada de subjetividad | Titular y oraciones del primer párrafo (subcorpus) | Precisión, *recall*, F1 |
| **B · Fuentes** | Extracción de atribuciones + detección de postura (cascada) | Oraciones con cita directa o indirecta (subcorpus) | F1 macro; Gini de voces |
| **C · Cobertura** | Modelado dinámico de tópicos (no supervisado) | Corpus completo de titulares, por trimestre | Jensen-Shannon; NPMI |
| **D · Encuadre** | Clasificación supervisada multietiqueta | Titular y primer párrafo, dentro de un mismo evento | F1 macro y micro |
| **Transversal** | Agrupamiento (*clustering*) por evento | Titulares en ventanas de ±2 días | ARI, pureza, B-cubed |

donde $G = 0$ indica que todas las clases reciben las mismas citas.

## 5.4. Dimensión C: qué se enfatiza u omite

**Enfoque.** Modelado dinámico de tópicos sobre el corpus completo, por trimestres, comparando la distribución de cada medio con la del resto.

**Justificación.** El énfasis y la omisión solo se ven en el agregado y en el tiempo [12]. El LDA de esta entrega muestra el punto de partida y sus límites: perfiles no uniformes, pero tópicos que mezclan agenda y formato. La versión dinámica [33] encadena los tópicos entre periodos, de modo que un tema se pueda seguir en el tiempo y entre gobiernos.

**Modelos.** (1) LDA estático por periodo (la línea base de esta entrega); (2) el modelo dinámico de tópicos [33]; (3) BERTopic con tópicos en el tiempo [34], que agrupa embeddings y suele funcionar mejor con textos cortos. Para elegir modelo: coherencia NPMI, diversidad de tópicos y varias semillas. Para comparar medios: divergencia de Jensen-Shannon por periodo [17], ya usada en la Sección 2.8.

## 5.5. Dimensión D: cómo se enmarca el hecho

**Enfoque.** Clasificación supervisada multietiqueta de encuadres en competencia por tipo de hecho: criminalización frente a reivindicación en protestas; encuadre bélico frente a diálogo en el conflicto armado [35]; crisis frente a logro en la gestión del gobierno.

**Justificación.** El encuadre es una propiedad del texto que un anotador reconoce con una guía [26], así que admite supervisión. Pastorino et al. muestran que los LLM detectan encuadres de forma inconsistente y sensible a la redacción de la instrucción [36]: el LLM se compara, pero no reemplaza un clasificador entrenado con anotaciones propias. Las coocurrencias de la Sección 2.7 (vocabulario policial en la cobertura del conflicto en RCN y Caracol) son hipótesis concretas para esta dimensión.

**Modelos.** (1) Lexicón de marcos y regresión logística uno-contra-todos sobre TF-IDF; (2) *transformer* en español con una salida sigmoide por etiqueta; (3) LLM con

**Tabla 9:** Criterios de comparación de modelos.

| Criterio | Cómo se mide |
|---|---|
| Desempeño | F1 macro y micro con intervalos *bootstrap* del 95 %; diferencias con *bootstrap* pareado o McNemar |
| Robustez contrafactual | Cambio de la predicción al intercambiar nombres de actores y medios (CDA) [27, 30] |
| Carga emocional | Desempeño estratificado por intensidad emocional; correlación parcial con un detector de emociones [38] |
| Robustez temporal | Entrenar en un gobierno y evaluar en el otro (Duque ↔ Petro) |
| Acuerdo perspectivista | Entropía cruzada frente a la distribución de etiquetas de los anotadores [27] |
| Interpretabilidad | Evidencia textual de cada predicción (coeficientes, atribución por gradientes, justificación del LLM) |
| Costo | Tiempo y hardware por cada 1 000 textos |

pocos ejemplos.

## 5.6. Agrupamiento por evento

Todas las dimensiones comparan medios sobre el mismo hecho, así que primero hay que reunir las coberturas de cada evento. La Sección IV mostró que TF-IDF ya recupera el mismo hecho entre medios en ambos cortes. Se compararán: (1) TF-IDF con agrupamiento jerárquico en ventanas de dos días; (2) embeddings de Sentence-BERT con HDBSCAN; y (3) cualquiera de los anteriores más una verificación por pares con un LLM. Se evalúan con unos 200 eventos agrupados a mano, usando el índice de Rand ajustado, la pureza y F1 B-cubed.

## 5.7. Comparación de modelos y criterios

Sí se comparará más de un modelo. La comparación principal es la de la tercera pregunta de investigación: una **cascada de clasificadores especializados** (un *transformer* en español de unos 110 millones de parámetros por tarea) frente a un **LLM ajustado** con LoRA [37] que produce todas las etiquetas a la vez. Se incluyen como referencias la línea base clásica y un LLM sin ajuste. Los criterios se resumen en la Tabla 9.

Las particiones se hacen por evento, para que ningún hecho quede a la vez en entrenamiento y prueba. Si dos modelos no difieren de forma significativa en F1, se elige el más robusto y el más barato.

## 5.8. Anotación y validación

Los modelos supervisados necesitan datos anotados que hoy no existen. Se propone una fase piloto de 1 200 artículos (200 por medio) con texto completo, estratificados por medio, tipo de hecho y periodo, y concentrados en eventos cubiertos por al menos tres medios. Los anotarán al menos tres integrantes con una guía escrita, y se medirá el acuerdo con el alfa de Krippendorff [39]. Se conservarán las etiquetas de todos los anotadores (anotación perspectivista [27]) y se generarán variantes contrafactuales que intercambian actores de la misma clase. Después se escalará hacia 5 000–10 000 artículos con preanotación de un LLM corregida por personas.

## 5.9. Relación con las preguntas de investigación

- **PI 1** (¿cambian tópicos y encuadres según la concordancia ideológica con el gobierno?): ahora es abordable, porque la base unificada contiene dos gobiernos completos (Duque y Petro) con los mismos cinco medios. Se responde con las dimensiones C y D por gobierno. Falta una medida externa de la línea editorial de cada medio.
- **PI 2** (¿coinciden los medios de verificación al evaluar los mismos contenidos?) [40]: requiere recolectar La Silla Vacía, Colombiacheck y AFP Factual, que no están en el corpus; si no, debe reformularse.
- **PI 3** (cascada frente a LLM): se responde con la comparación de la Sección 5.8.

# VI. LIMITACIONES Y CONCLUSIONES

**Lo que se puede afirmar:**

- La integridad técnica del corpus y de los resultados (46 verificaciones).
- Los medios difieren en cobertura temática, diversidad léxica y perfiles de tópicos, con efectos pequeños ($V \leq 0{,}059$).
- Los géneros (programas, emisiones, opinión) dominan buena parte de las diferencias léxicas.
- TF-IDF recupera la cobertura de un mismo hecho entre medios.

**Lo que no se puede afirmar:**

- Sesgo editorial confirmado ni descartado, intención política o una agenda común.
- Que los tópicos LDA estén validados, ni que la ventaja de $K = 5$ sea estable entre semillas.

- Nada sobre Cambio en este corte, con 98 registros en seis días.

**Limitaciones principales:**

- **Titulares reconstruidos.** Sin cuerpo, sin comillas y con posibles cambios del titular publicado.
- **Fechas.** Parte de las fechas de día provienen del `lastmod` y 38 621 solo tienen precisión de mes.
- **Independencia.** 32 368 titulares repetidos hacen optimistas las pruebas.
- **Validación.** No hay anotación humana de temas, tópicos ni encuadres.

Los siguientes pasos son los de la Sección V: separar géneros, recuperar el texto de un subcorpus balanceado, anotarlo y entrenar y comparar los modelos por dimensión.

## Referencias


[1] C. D. Manning, P. Raghavan, and H. Schütze, *Introduction to Information Retrieval*. Cambridge University Press, 2008.

[2] G. K. Zipf, *Human Behavior and the Principle of Least Effort*. Addison-Wesley, 1949.

[3] A. Clauset, C. R. Shalizi, and M. E. J. Newman, "Power-law distributions in empirical data," *SIAM Review*, vol. 51, no. 4, pp. 661–703, 2009.

[4] H. S. Heaps, *Information Retrieval: Computational and Theoretical Aspects*. Academic Press, 1978.

[5] F. J. Tweedie and R. H. Baayen, "How variable may a constant be? measures of lexical richness in perspective," *Computers and the Humanities*, vol. 32, no. 5, pp. 323–352, 1998.

[6] G. U. Yule, *The Statistical Study of Literary Vocabulary*. Cambridge University Press, 1944.

[7] International Organization for Standardization, "ISO 25964-1:2011. information and documentation — thesauri and interoperability with other vocabularies — part 1: Thesauri for information retrieval," 2011.

[8] A. Miles and S. Bechhofer, "SKOS simple knowledge organization system reference." W3C Recommendation, 2009.

[9] T. R. Gruber, "A translation approach to portable ontology specifications," *Knowledge Acquisition*, vol. 5, no. 2, pp. 199–220, 1993.

[10] N. F. Noy and D. L. McGuinness, "Ontology development 101: A guide to creating your first ontology," Tech. Rep. KSL-01-05, Stanford Knowledge Systems Laboratory, 2001.

[11] J. Grimmer and B. M. Stewart, "Text as data: The promise and pitfalls of automatic content analysis methods for political texts," *Political Analysis*, vol. 21, no. 3, pp. 267–297, 2013.

[12] M. E. McCombs and D. L. Shaw, "The agenda-setting function of mass media," *Public Opinion Quarterly*, vol. 36, no. 2, pp. 176–187, 1972.

[13] E. B. Wilson, "Probable inference, the law of succession, and statistical inference," *Journal of the American Statistical Association*, vol. 22, no. 158, pp. 209–212, 1927.

[14] S. Holm, "A simple sequentially rejective multiple test procedure," *Scandinavian Journal of Statistics*, vol. 6, no. 2, pp. 65–70, 1979.

[15] D. M. Blei, A. Y. Ng, and M. I. Jordan, "Latent Dirichlet allocation," *Journal of Machine Learning Research*, vol. 3, pp. 993–1022, 2003.

[16] M. Röder, A. Both, and A. Hinneburg, "Exploring the space of topic coherence measures," in *Proceedings of the Eighth ACM International Conference on Web Search and Data Mining (WSDM)*, pp. 399–408, 2015.

[17] J. Lin, "Divergence measures based on the Shannon entropy," *IEEE Transactions on Information Theory*, vol. 37, no. 1, pp. 145–151, 1991.

[18] F. Hamborg, K. Donnay, and B. Gipp, "Automated identification of media bias in news articles: An interdisciplinary literature review," *International Journal on Digital Libraries*, vol. 20, no. 4, pp. 391–415, 2019.

[19] F. Hamborg, "Media bias, the social sciences, and NLP: Automating frame analyses to identify bias by word choice and labeling," in *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics: Student Research Workshop*, Association for Computational Linguistics, 2020.

[20] K. Spärck Jones, "A statistical interpretation of term specificity and its application in retrieval," *Journal of Documentation*, vol. 28, no. 1, pp. 11–21, 1972.

[21] G. Salton and C. Buckley, "Term-weighting approaches in automatic text retrieval," *Information Processing & Management*, vol. 24, no. 5, pp. 513–523, 1988.

[22] T. Mikolov, I. Sutskever, K. Chen, G. Corrado, and J. Dean, "Distributed representations of words and phrases and their compositionality," in *Advances in Neural Information Processing Systems 26 (NIPS)*, pp. 3111–3119, 2013.

[23] P. Bojanowski, E. Grave, A. Joulin, and T. Mikolov, "Enriching word vectors with subword information," *Transactions of the Association for Computational Linguistics*, vol. 5, pp. 135–146, 2017.

[24] N. Reimers and I. Gurevych, "Sentence-BERT: Sentence embeddings using Siamese BERT-networks," in *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing (EMNLP-IJCNLP)*, pp. 3982–3992, 2019.

[25] L. van der Maaten and G. Hinton, "Visualizing data using t-SNE," *Journal of Machine Learning Research*, vol. 9, pp. 2579–2605, 2008.

[26] R. M. Entman, "Framing: Toward clarification of a fractured paradigm," *Journal of Communication*, vol. 43, no. 4, pp. 51–58, 1993.

[27] F.-J. Rodrigo-Ginés, J. Carrillo-de Albornoz, and L. Plaza, "Media bias bias-mitigated dataset (MBBMD): A hierarchical, perspectivist, and counterfactually-augmented corpus for bias detection in Spanish news," *Procesamiento del Lenguaje Natural*, vol. 76, pp. 53–64, 2026.

[28] J. Cañete, G. Chaperon, R. Fuentes, J.-H. Ho, H. Kang, and J. Pérez, "Spanish pre-trained BERT model and evaluation data," in *PML4DC Workshop at ICLR*, 2020.

[29] A. Gutiérrez-Fandiño *et al.*, "MarIA: Spanish language models," *Procesamiento del Lenguaje Natural*, vol. 68, pp. 39–60, 2022.

[30] K. Salas-Jiménez, S.-L. Ojeda-Trueba, G. Bel-Enguix, E. Lee-Romero, and F. F. López-Ponce, "An LLM-based methodology for the automatic detection of bias in the DuoWikiBias corpus," *Frontiers in Artificial Intelligence*, vol. 9, p. 1791624, 2026.

[31] D. Lee, J. Choi, J. Han, and K. Park, "Journalism-guided agentic in-context learning for news stance detection." arXiv:2507.11049v2, 2025.

[32] M. Burnham, "Stance detection: A practical guide to classifying political beliefs in text," *Political Science Research and Methods*, vol. 13, no. 3, pp. 611–628, 2024.

[33] D. M. Blei and J. D. Lafferty, "Dynamic topic models," in *Proceedings of the 23rd International Conference on Machine Learning (ICML)*, pp. 113–120, 2006.

[34] M. Grootendorst, "BERTopic: Neural topic modeling with a class-based TF-IDF procedure." arXiv:2203.05794, 2022.

[35] A.-L. Dießelmann and A. Hetzer, "Encuadres visuales en las fotografías de prensa del proceso de paz en Colombia," *Universitas Humanística*, vol. 88, pp. 1–36, 2019.

[36] V. Pastorino, J. A. Sivakumar, and N. S. Moosavi, "Decoding news narratives: A critical analysis of large language models in framing detection," in *Proceedings of the 3rd Workshop on Natural Language Processing for Political Sciences (PoliticalNLP)*, pp. 17–28, 2026.

[37] E. J. Hu, Y. Shen, P. Wallis, Z. Allen-Zhu, Y. Li, S. Wang, L. Wang, and W. Chen, "LoRA: Low-rank adaptation of large language models," in *International Conference on Learning Representations (ICLR)*, 2022.

[38] Ó. Moreno-Martínez, "El círculo vicioso de la expresión violenta y la polarización ideológico-afectiva en tiempos de COVID-19," *Signo y Pensamiento*, vol. 42, pp. 1–18, 2023.

[39] K. Krippendorff, *Content Analysis: An Introduction to Its Methodology*. Sage, 2 ed., 2004.

[40] C. Rodríguez-Pérez, "Desinformación online y fact-checking en entornos de polarización social: el periodismo de verificación de Colombiacheck, La Silla Vacía y AFP durante la huelga nacional del 21N en Colombia," *Estudios sobre el Mensaje Periodístico*, vol. 27, no. 2, pp. 623–637, 2021.