# Asistente RAG reproducible sobre prensa y Bluesky colombianos con Milvus y LLM locales

Abel Albuez Sánchez, Kelly Joane León Torres, Juan Camilo Torres Peña y Jesús David Romero Melo
Maestría en Inteligencia Artificial, Pontificia Universidad Javeriana
Profesor: Ing. Luis Gabriel Moreno Sandoval, PhD
Repositorio: https://github.com/AbelAlbuez/natural-language-processing-workshops

***Resumen*—Este documento describe el corpus, la segmentación, la arquitectura y el protocolo de evaluación de un asistente de generación aumentada por recuperación (RAG) sobre noticias y publicaciones de Bluesky en español e inglés. El corpus preparado contiene 146.923 documentos y la segmentación por tokens 256/48 produce 577.324 chunks, ambos verificados. La pila prevista usa Milvus standalone v2.6.25 sin MinIO, ya validado, y modelos de lenguaje locales servidos con Ollama. Los pesos del encoder `intfloat/multilingual-e5-small` están descargados y cargan sin conexión. El protocolo divide un gold standard de 40 preguntas en 20 de desarrollo y 20 de prueba. Los embeddings, la carga en Milvus, la API, la interfaz, los experimentos y la evaluación humana están pendientes; este documento no presenta resultados experimentales. Las referencias bibliográficas están por verificar.**

***Index Terms*—RAG, recuperación de información, corpus bilingüe, segmentación, embeddings, Milvus, LLM locales, evaluación**

## I. Problema e hipótesis

El proyecto estudia la recuperación de evidencia en un corpus de prensa y publicaciones sociales colombianas en español e inglés. La hipótesis de trabajo PI6 propone que Recall@5 es menor para Bluesky que para Media Cloud al comparar preguntas del mismo idioma por separado, y que la abstención correcta es menor para preguntas en inglés que para preguntas en español. Es una hipótesis pendiente de evaluación.

El protocolo prevé reportar Recall@k ($k \in \{1, 3, 5, 10\}$), MRR, nDCG@10, abstención correcta y fidelidad de citas, desglosados por fuente esperada e idioma. Las métricas siguen referencias candidatas aún no verificadas [22], [25].

## II. Corpus y perfilado (A)

El diagnóstico del proyecto registra 169.248 documentos originales y 146.923 después de la preparación bilingüe: 64.666 en español y 82.257 en inglés. El recuento de 146.923 filas del Parquet preparado se comprobó por metadatos. Las cifras se documentan en `docs/diagnostico_corpus.md` y `docs/prepare_stats_es_en.json`; no se incluye texto de documentos.

## III. Segmentación (B)

La segmentación por tokens usa ventanas de 256 tokens con solapamiento de 48 y produce 577.324 chunks en `data/chunks_tok256.parquet`. Al retokenizar, 40.474 chunks superan 256 tokens, con un máximo de 258. Por documento, la mediana es de 3 chunks, el percentil 95 de 10 y el máximo de 426. Estas cifras están verificadas.

Cuadro I
Tamaño del corpus preparado.

| Etapa o idioma | Documentos |
|---|---|
| Originales | 169.248 |
| Preparados, total | 146.923 |
| Español | 64.666 |
| Inglés | 82.257 |

## IV. Embeddings (C)

El proyecto usa `intfloat/multilingual-e5-small` con el prefijo `passage:` para documentos y `query:` para consultas [6], [7]. Los pesos se descargaron en la caché local de Hugging Face, fijados a la revisión `614241f`. Se bajaron solo los archivos necesarios para PyTorch y sentence-transformers: unos 493 MB, o 470 MiB en disco. La carga sin conexión con `AutoTokenizer` y `AutoModel` (`local_files_only=True`) funcionó: el modelo tiene una dimensión oculta de 384 y 117.653.760 parámetros. Todavía no se han calculado embeddings, así que normalización, latencia y consumo de memoria siguen sin medir. La comparación con otros encoders también está pendiente.

## V. Milvus (D)

La pila usa Milvus standalone v2.6.25 con etcd embebido y almacenamiento local, sin MinIO. Esta configuración está validada. La colección prevista es `rag_e5s_tok256_v1`; la carga de vectores está pendiente.

## VI. Diseño experimental (5)

El plan propuesto empieza con un piloto de 500 documentos y escala a 10.000 y luego al corpus completo solo si el hardware lo permite. El piloto se seleccionó con semilla 42, estratificado por fuente (`source`) e idioma (`lang`). La Tabla II solo informa conteos.

Entre condiciones experimentales solo cambia el LLM; corpus, segmentación, encoder, índice, `top-k` y prompt se mantienen fijos. Según `docs/EVALUACION.md`, cada condición se repetirá al menos tres veces, registrando el arranque en frío y en caliente. Los modelos locales previstos se servirán

Cuadro II
CONTEOS DEL PILOTO DE 500 DOCUMENTOS POR FUENTE E IDIOMA.

| Fuente | es | en | Total |
|---|---|---|---|
| Bluesky | 18 | 159 | 177 |
| GDELT | 1 | 1 | 2 |
| Media Cloud | 201 | 120 | 321 |
| Total | 220 | 280 | 500 |

con Ollama [26]–[28]. Todavía no se han medido la viabilidad en hardware, el tiempo de indexación ni ninguna métrica. Las referencias de evaluación automática son candidatas por verificar [5], [22], [23].

## VII. GOLD STANDARD Y PARTICIÓN (6)

El gold standard contiene 40 preguntas: 22 en español y 18 en inglés. Su contenido está pendiente de revisión por el equipo. La Tabla III muestra la distribución por fuente esperada e idioma.

Cuadro III
DISTRIBUCIÓN DEL GOLD STANDARD.

| Fuente esperada | es | en | Total |
|---|---|---|---|
| Media Cloud | 16 | 9 | 25 |
| Bluesky | 5 | 9 | 14 |
| GDELT | 1 | 0 | 1 |
| Total | 22 | 18 | 40 |

La partición vigente, registrada en `docs/protocolo_evaluacion.md`, divide las 40 preguntas en 20 de desarrollo y 20 de prueba. Usa los IDs de `docs/gold_standard_plantilla.csv`, semilla 42 y estratificación por fuente esperada e idioma de la pregunta, con cuotas asignadas por mayor resto (Tabla IV). El único caso GDELT en español va a prueba, porque un estrato de un solo caso no puede quedar en ambas particiones. Los parámetros se ajustan solo con desarrollo y se congelan antes de evaluar con prueba.

Cuadro IV
PARTICIÓN DESARROLLO/PRUEBA DEL GOLD STANDARD.

| Fuente esperada | Idioma | Desarrollo | Prueba | Total |
|---|---|---|---|---|
| Bluesky | en | 5 | 4 | 9 |
| Bluesky | es | 2 | 3 | 5 |
| GDELT | es | 0 | 1 | 1 |
| Media Cloud | en | 5 | 4 | 9 |
| Media Cloud | es | 8 | 8 | 16 |
| Total | | 20 | 20 | 40 |

La evaluación humana independiente, la rúbrica y la resolución de desacuerdos están pendientes.

## VIII. DECISIONES DE ARQUITECTURA

La configuración prevista combina los documentos preparados, la segmentación 256/48, embeddings E5 con prefijo de pasaje, Milvus como almacén vectorial, una API FastAPI, una interfaz Streamlit y LLM locales servidos con Ollama. La elección del encoder no se considera justificada hasta completar una comparación controlada. Las referencias sobre recuperación híbrida y embeddings son candidatas por verificar [1]–[4], [8], [9].

## IX. LIMITACIONES Y AMENAZAS A LA VALIDEZ

El gold standard es pequeño y está desequilibrado: Bluesky en español tiene cinco preguntas y GDELT una. Con la partición, la prueba queda con tres preguntas de Bluesky en español y una de GDELT, así que esos estratos tendrán alta incertidumbre. La preparación, los filtros de idioma y la segmentación determinan la población evaluada; cualquier cambio exige documentar una nueva versión de los datos. Todas las referencias permanecen por verificar.

## X. PENDIENTES

- Revisión del gold standard por el equipo.
- Cálculo de embeddings y carga de la colección en Milvus.
- Puesta en marcha de la API, la interfaz Streamlit y Ollama con los modelos elegidos.
- Experimentos: piloto, 10.000 documentos y corpus completo si los recursos lo permiten, con métricas, tiempos, recursos y repeticiones por condición.
- Evaluación humana, medición del acuerdo y resolución de desacuerdos.
- Justificación del encoder frente a alternativas.
- Verificación de cada referencia contra su fuente original.

## REFERENCIAS


[1] S. Robertson y H. Zaragoza, "The Probabilistic Relevance Framework: BM25 and Beyond," 2009, doi:10.1561/1500000019. *Por verificar.*

[2] G. V. Cormack, C. L. A. Clarke y S. Büttcher, "Reciprocal Rank Fusion Outperforms Condorcet and Individual Rank Learning Methods," 2009, doi:10.1145/1571941.1572114. *Por verificar.*

[3] V. Karpukhin et al., "Dense Passage Retrieval for Open-Domain Question Answering," 2020, arXiv:2004.04906. *Por verificar.*

[4] T. Formal, B. Piwowarski y S. Clinchant, "SPLADE: Sparse Lexical and Expansion Model for First Stage Ranking," 2021, arXiv:2107.05720. *Por verificar.*

[5] N. Thakur et al., "BEIR: A Heterogeneous Benchmark for Zero-shot Evaluation of Information Retrieval Models," 2021, arXiv:2104.08663. *Por verificar.*

[6] L. Wang et al., "Text Embeddings by Weakly-Supervised Contrastive Pre-training," 2022, arXiv:2212.03533. *Por verificar.*

[7] L. Wang et al., "Multilingual E5 Text Embeddings: A Technical Report," 2024, arXiv:2402.05672. *Por verificar.*

[8] J. Chen et al., "BGE M3-Embedding: Multi-Lingual, Multi-Functionality, Multi-Granularity Text Embeddings Through Self-Knowledge Distillation," 2024, arXiv:2402.03216. *Por verificar.*

[9] N. Muennighoff et al., "MTEB: Massive Text Embedding Benchmark," 2022, arXiv:2210.07316. *Por verificar.*

[10] X. Zhang et al., "MIRACL: A Multilingual Retrieval Dataset Covering 18 Diverse Languages," 2023, arXiv:2210.09984. *Por verificar.*

[11] R. Nogueira y K. Cho, "Passage Re-ranking with BERT," 2019, arXiv:1901.04085. *Por verificar.*

[12] O. Khattab y M. Zaharia, "ColBERT: Efficient and Effective Passage Search via Contextualized Late Interaction over BERT," 2020, arXiv:2004.12832. *Por verificar.*

[13] W. Sun et al., "Is ChatGPT Good at Search? Investigating Large Language Models as Re-Ranking Agents," 2023, arXiv:2304.09542. *Por verificar.*

[14] Anthropic, "Introducing Contextual Retrieval," 2024, https://www.anthropic.com/news/contextual-retrieval. *Por verificar.*

[15] M. Günther et al., “Late Chunking: Contextual Chunk Embeddings Using Long-Context Embedding Models,” 2024, arXiv:2409.04701. *Por verificar*.
[16] P. Sarthi et al., “RAPTOR: Recursive Abstractive Processing for Tree-Organized Retrieval,” 2024, arXiv:2401.18059. *Por verificar*.
[17] N. F. Liu et al., “Lost in the Middle: How Language Models Use Long Contexts,” 2023, arXiv:2307.03172. *Por verificar*.
[18] S.-Q. Yan et al., “Corrective Retrieval Augmented Generation (CRAG),” 2024, arXiv:2401.15884. *Por verificar*.
[19] A. Asai et al., “Self-RAG: Learning to Retrieve, Generate, and Critique through Self-Reflection,” 2023, arXiv:2310.11511. *Por verificar*.
[20] P. Rajpurkar, R. Jia y P. Liang, “Know What You Don’t Know: Unanswerable Questions for SQuAD,” 2018, arXiv:1806.03822. *Por verificar*.
[21] B. Wen et al., “Know Your Limits: A Survey of Abstention in Large Language Models,” 2024, arXiv:2407.18418. *Por verificar*.
[22] S. Es et al., “RAGAS: Automated Evaluation of Retrieval Augmented Generation,” 2023, arXiv:2309.15217. *Por verificar*.
[23] J. Saad-Falcon et al., “ARES: An Automated Evaluation Framework for Retrieval-Augmented Generation Systems,” 2023, arXiv:2311.09476. *Por verificar*.
[24] L. Zheng et al., “Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena,” 2023, arXiv:2306.05685. *Por verificar*.
[25] K. Järvelin y J. Kekäläinen, “Cumulated Gain-Based Evaluation of IR Techniques,” 2002, doi:10.1145/582415.582418. *Por verificar*.
[26] Qwen Team, “Qwen2.5 Technical Report,” 2024, arXiv:2412.15115. *Por verificar*.
[27] Gemma Team, “Gemma 2: Improving Open Language Models at a Practical Size,” 2024, arXiv:2408.00118. *Por verificar*.
[28] A. Grattafiori et al. (Llama Team), “The Llama 3 Herd of Models,” 2024, arXiv:2407.21783. *Por verificar*.
[29] M. Abdin et al., “Phi-3 Technical Report: A Highly Capable Language Model Locally on Your Phone,” 2024, arXiv:2404.14219. *Por verificar*.
[30] A. Z. Broder, “On the Resemblance and Containment of Documents,” 1997, doi:10.1109/SEQUEN.1997.666900. *Por verificar*.
[31] M. S. Charikar, “Similarity Estimation Techniques from Rounding Algorithms,” 2002, doi:10.1145/509907.509965. *Por verificar*.
[32] J. Leskovec, L. Backstrom y J. Kleinberg, “Meme-tracking and the Dynamics of the News Cycle,” 2009, doi:10.1145/1557019.1557077. *Por verificar*.
[33] K. Greshake et al., “Not What You’ve Signed Up For: Compromising Real-World LLM-Integrated Applications with Indirect Prompt Injection,” 2023, arXiv:2302.12173. *Por verificar*.
[34] W. Zou et al., “PoisonedRAG: Knowledge Corruption Attacks to Retrieval-Augmented Generation of Large Language Models,” 2024, arXiv:2402.07867. *Por verificar*.